

پردیس علوم
دانشکده ریاضی، آمار و علوم کامپیوتر

بررسی هندسی شبکه‌های عصبی عمیق

نگارنده

پریناز قاسمی

استاد راهنما: دکتر آرتا جمشیدی

پروژه برای دریافت درجه کارشناسی
در رشته علوم کامپیوتر

شهریور ۱۴۰۵

چکیده

شبکه‌های عصبی عمیق می‌توانند به دقت بالایی در طبقه‌بندی دست یابند، اما رسیدن به دقت بالا لزوماً به معنای ثابت شدن بازنمایی‌های[1] داخلی شبکه نیست. بررسی تغییرات این بازنمایی‌ها می‌تواند درک بهتری از روند یادگیری و همگرایی شبکه‌های عصبی عمیق فراهم کند.

در این پژوهش، روند تغییر بازنمایی‌های داخلی و ساختار هندسی ویژگی‌های یادگرفته‌شده در طول آموزش یک شبکه ResNet-18 بر روی مجموعه‌داده CIFAR-10 بررسی شده است. شبکه به مدت ۳۵۰ دوره[2] آموزش داده شد. برای بررسی تغییر بازنمایی‌ها، از معیار هم‌ترازی کرنل مرکزی[3] استفاده شد که بازنمایی لایه‌های مختلف را در دوره‌های آموزش با بازنمایی نهایی مقایسه می‌کند. همچنین، ساختار هندسی ویژگی‌ها با معیارهای مربوط به پراکندگی درون‌کلاسی، فاصله میان کلاس‌ها، ارتباط ویژگی‌ها با طبقه‌بند و توافق میان پیش‌بینی شبکه و پیش‌بینی بر اساس میانگین ویژگی‌های کلاس‌ها ارزیابی شد. دقت آموزش و تابع زیان نیز برای بررسی عملکرد مدل در طول آموزش مورد استفاده قرار گرفتند.

نتایج این بررسی نشان می‌دهند که لایه‌های مختلف شبکه در زمان یکسانی به وضعیت پایدار نمی‌رسند. لایه کانولوشنی اولیه بسیار زودتر از سایر لایه‌ها به شباهت بالا با بازنمایی نهایی می‌رسد، در حالی که بقیه لایه‌ها، به‌ویژه لایه‌های عمیق‌تر، تا مراحل پایانی آموزش همچنان تغییر می‌کنند. همچنین، ساختار هندسی ویژگی‌ها پس از رسیدن دقت آموزش به مقادیر نزدیک به ۱۰۰ درصد نیز می‌تواند به تغییر ادامه دهد.

در مجموع، یافته‌های این پژوهش بیانگر آن هستند که فرآیند یادگیری شبکه در مراحل پایانی آموزش همچنان از نظر ساختار بازنمایی‌ها در حال تکامل است. تفاوت در زمان پایداری لایه‌ها و ادامه شکل‌گیری ساختار هندسی ویژگی‌ها نشان می‌دهد که همگرایی عملکردی شبکه الزاماً با همگرایی بازنمایی‌های داخلی آن هم‌زمان نیست. از این رو، مطالعه روند تکامل بازنمایی‌ها می‌تواند درک دقیق‌تری از فرآیند یادگیری شبکه‌های عصبی عمیق فراهم کند.

کلیدواژه‌ها: تغییرات داخلی شبکه، هم‌ترازی کرنل مرکزی، ساختار هندسی ویژگی‌ها، یادگیری بازنمایی، CIFAR-10، ResNet-18

[1] Representation

[2] Epoch

[3] Centered Kernel Alignment

سپاسگزاری

از استاد راهنمای بزرگوارم، که با راهنمایی‌های ارزشمند و حمایت‌های بی‌دریغ، مسیر انجام این پژوهش را برای من هموار ساختند، کمال تشکر و قدردانی را دارم.

پیشگفتار

شبکه‌های عصبی عمیق در سال‌های اخیر به بخش مهمی از سامانه‌های یادگیری ماشین تبدیل شده‌اند و توانایی بالایی در یادگیری الگوهای پیچیده، به‌ویژه در پردازش و طبقه‌بندی تصاویر، نشان داده‌اند. با وجود عملکرد قابل توجه این مدل‌ها، پرسش‌هایی درباره چگونگی شکل‌گیری بازنمایی‌های[۴] داخلی آن‌ها در طول آموزش و زمان رسیدن این بازنمایی‌ها به یک وضعیت پایدار همچنان مطرح است.

روند یادگیری شبکه معمولاً با معیارهایی مانند دقت طبقه‌بندی و مقدار تابع زیان ارزیابی می‌شود. اگرچه این معیارها برای سنجش عملکرد شبکه مهم هستند، اطلاعات کاملی درباره تغییرات بازنمایی‌های داخلی ارائه نمی‌کنند. ممکن است شبکه به دقت بسیار بالایی برسد، در حالی که بازنمایی‌های داخلی آن همچنان در حال تغییر باشند. بنابراین، بررسی مستقیم بازنمایی‌ها می‌تواند دید کامل‌تری از فرآیند یادگیری فراهم کند.

یکی از موضوعات مهم در مطالعه ساختار بازنمایی‌های شبکه‌های عصبی، پدیده «فروپاشی عصبی»[۵] است. مطالعات نشان داده‌اند که در مراحل پایانی آموزش، ویژگی‌های آموخته‌شده می‌توانند به سمت ساختاری منظم حرکت کنند؛ به‌گونه‌ای که ویژگی‌های نمونه‌های یک کلاس به یکدیگر نزدیک‌تر و کلاس‌های مختلف از یکدیگر جدا می‌شوند. این موضوع نشان می‌دهد که یادگیری شبکه تنها به افزایش دقت محدود نمی‌شود و تغییرات مهمی در ساختار هندسی فضای بازنمایی نیز رخ می‌دهد.

[4] Representation

[5] Neural Collapse

در کنار این موضوع، معیار هم‌ترازی کرنل مرکزی[6] امکان بررسی تغییرات بازنمایی‌های داخلی در طول آموزش را فراهم می‌کند. با استفاده از این معیار می‌توان میزان شباهت بازنمایی هر لایه در مراحل مختلف آموزش با بازنمایی نهایی آن را بررسی کرد و روند تثبیت بازنمایی‌ها را مطالعه نمود. بررسی این معیار در کنار ساختار هندسی ویژگی‌ها می‌تواند دید کامل‌تری از روند یادگیری شبکه ارائه دهد.

بر این اساس، پرسش اصلی این پژوهش آن است که تغییرات بازنمایی‌های داخلی شبکه در طول آموزش چگونه با شکل‌گیری ساختار هندسی ویژگی‌های آموخته‌شده ارتباط دارد. برای بررسی این مسئله، از معماری ResNet-18 و مجموعه‌داده CIFAR-10 استفاده شده است. روند آموزش شبکه در ۳۵۰ دوره بررسی شده و تغییرات بازنمایی‌های داخلی، ساختار هندسی ویژگی‌ها، دقت آموزش و تابع زیان در مراحل مختلف آموزش مورد مطالعه قرار گرفته‌اند.

اهمیت این بررسی در آن است که دقت نهایی شبکه به تنهایی نمی‌تواند تمام فرآیند یادگیری را توضیح دهد. ممکن است شبکه از نظر عملکرد به سطح بالایی رسیده باشد، اما بازنمایی‌های داخلی آن همچنان در حال تغییر و سازمان‌یافتگی باشند. بررسی هم‌زمان این جنبه‌ها می‌تواند به درک بهتر فرآیند یادگیری و تغییرات بازنمایی‌های داخلی شبکه کمک کند.

ساختار این پایان‌نامه در پنج فصل تنظیم شده است. در فصل اول، مفاهیم مقدماتی و مبانی لازم برای درک موضوع پژوهش معرفی می‌شوند. در فصل دوم، مطالعات و مقالات مرتبط مرور می‌شوند. فصل سوم به طرح آزمایش و نحوه انجام پژوهش اختصاص دارد. در فصل چهارم، نتایج آزمایش‌ها ارائه و تحلیل می‌شوند. در نهایت، فصل پنجم به نتیجه‌گیری و ارائه پیشنهادهایی برای کارهای آینده اختصاص دارد.

[6] Centered Kernel Alignment

فهرست مطالب

۱ مفاهیم مقدماتی ۱

۱.۱ شبکه‌های عصبی عمیق ۱

۱.۱.۱ نورون مصنوعی و پرسپترون ۱

۲.۱.۱ شبکه‌های چندلایه ۲

۳.۱.۱ توابع فعال‌سازی ۳

۴.۱.۱ آموزش و بهینه‌سازی ۳

۵.۱.۱ شبکه ResNet-18 . . . . . ۳

۲.۱ بازنمایی در شبکه‌های عصبی ۴

۱.۲.۱ مفهوم بازنمایی ۴

۲.۲.۱ یادگیری سلسله‌مراتبی ویژگی‌ها ۵

۳.۱ فاز پایانی آموزش ۵

۴.۱ سادک ۶

۵.۱ کرنل ۷

۱.۵.۱ توابع کرنل ۷

۲.۵.۱ کرنل خطی و کرنل تابع پایه‌ی شعاعی ۸

۳.۵.۱ معیار استقلال هیلبرت‌ـاشمیت ۸

۴.۵.۱ تراز کرنل ۹

۲ پیشینه و مرور ادبیات **۱۰**
۱.۲ یادگیری بازنمایی در شبکه‌های عصبی عمیق ۱۰
۲.۲ سنجش شباهت بازنمایی‌ها ۱۲
۳.۲ مسئله‌ی هم‌ترازی ۱۳
۴.۲ تحلیل همبستگی کانونی ۱۳
۵.۲ محدودیت‌های CCA در یادگیری عمیق ۱۴
۶.۲ گذار به هم‌ترازی کرنل مرکزی ۱۵
۷.۲ هم‌ترازی کرنل مرکزی ۱۵
۸.۲ ماتریس گِرَم و شباهت ۱۵
۹.۲ تعریف CKA ۱۶
۱۰.۲ مزایا در تحلیل یادگیری عمیق ۱۷
۱۱.۲ فروپاشی عصبی ۱۷

۳ روش‌شناسی و طراحی آزمایش **۲۳**
۱.۳ چارچوب نظری ۲۳
۲.۳ روش تحقیق ۲۶
۳.۳ مجموعه‌داده و پیش‌پردازش ۲۷
۴.۳ معماری شبکه و تنظیمات آموزش ۲۹
۵.۳ استخراج ویژگی‌ها و محاسبه معیارها ۳۱
۱.۵.۳ معیار شباهت نمایش‌ها ۳۱
۲.۵.۳ معیار NC1 : فروپاشی درون کلاسی ۳۲
۳.۵.۳ معیار NC2 : ساختار سادک چارچوب تنگ هم‌زاویه ۳۳
۴.۵.۳ معیار NC3 : خوددوگانگی ۳۵
۵.۵.۳ معیار NC4 : معادل شدن رفتار طبقه‌بند با نزدیک‌ترین مرکز کلاس . ۳۶
۶.۳ طراحی آزمایش و معیار تعیین نقطه پایداری ۳۶

۴ آزمایش‌ها و نتایج **۳۸**
۱.۴ تکامل لایه‌ای نمایش‌ها در طول آموزش ۳۸
۲.۴ مسیر شکل‌گیری و تثبیت فروپاشی عصبی ۴۰
۳.۴ خطای آموزش و آغاز مرحله پایانی آموزش ۴۴
۴.۴ پویایی مشترک بازنمایی و فروپاشی عصبی ۴۵

۵ نتیجه گیری و کار آینده **۵۰**
۱.۵ پویایی آموزش ۵۰
۲.۵ کارهای آینده ۵۳

کتاب‌نامه **۵۸**

فهرست تصاویر

۱.۱ نورون مصنوعی و طبیعی ۲
۲.۱ ساختار شبکه عصبی ۲
۳.۱ ساختار شبکه ResNet-18 . . . . . ۴
۴.۱ فضای بازنمایی ۵
۱.۲ پدیده‌ی فروپاشی عصبی در طی فرایند آموزش ۲۲
۱.۳ معماری ResNet-18 مورد استفاده در پژوهش برای مجموعه‌داده CIFAR-10 ۲۹
۱.۴ همگرایی مؤلفه‌های فروپاشی عصبی ۴۱
۲.۴ مقایسه روند همگرایی فروپاشی عصبی و CKA ۴۸

فهرست جداول

۱.۳ خلاصه داده‌های مورد استفاده برای محاسبه معیارهای پژوهش ۲۹

۱.۴ دوره نخستین عبور و تثبیت سخت لایه‌های مختلف بر اساس معیار CKA . . ۳۹

۲.۴ زمان تثبیت مؤلفه‌های فروپاشی عصبی و مقایسه آن با مرز فاز نهایی آموزش. . ۴۲

۳.۴ مقایسه زمان تثبیت سخت مؤلفه‌های فروپاشی عصبی و لایه‌های مختلف بر اساس معیار CKA ۴۶

فصل ۱

مفاهیم مقدماتی

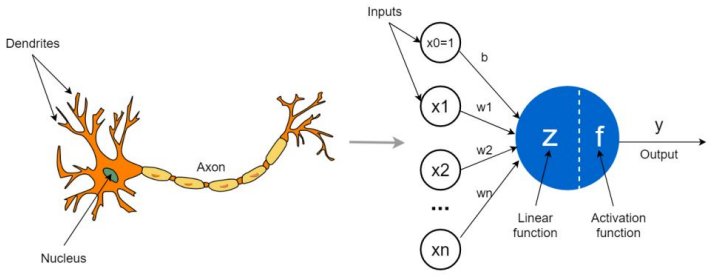
۱.۱ شبکه‌های عصبی عمیق

شبکه‌های عصبی عمیق[1] ستون فقرات یادگیری ماشین مدرن را تشکیل می‌دهند. این مدل‌ها با لایه‌بندی عملیات‌های غیرخطی، قادر به مدل‌سازی نگاشت‌های پیچیده میان ورودی‌ها و خروجی‌ها هستند [۹].

۱.۱.۱ نورون مصنوعی و پرسپترون

واحد بنیادی یک شبکه عصبی، نورون یا پرسپترون[2] است که ورودی‌های خود را با یک بردار وزن w ترکیب کرده و از یک تابع غیرخطی عبور می‌دهد. برای ورودی $x \in \mathbb{R}^d$، خروجی نورون به‌صورت $h = \sigma(w^T x + b)$ تعریف می‌شود که در آن b بایاس[3] و σ تابع فعال‌سازی است.

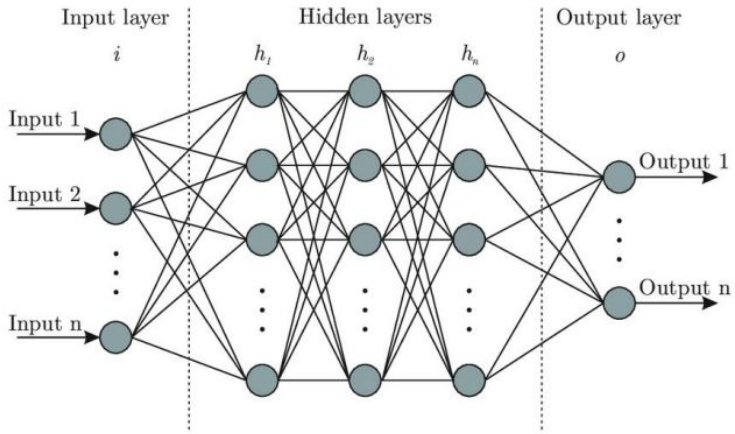
[1] Deep Neural Network
[2] Perceptron
[3] Bias



شکل ۱.۱: نورون مصنوعی و طبیعی [۱۳].

۲.۱.۱ شبکه‌های چندلایه

شبکه‌های عصبی چندلایه[۴]از اتصال متوالی نورون‌ها تشکیل شده‌اند. خروجی لایه l به‌صورت $z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}$ و $h^{(l)} = \sigma(z^{(l)})$ محاسبه می‌شود. این ساختار سلسله‌مراتبی اجازه می‌دهد شبکه مفاهیم پیچیده را به صورت بازگشتی از ترکیب ویژگی‌های لایه‌های پیشین بسازد [۱۰].



شکل ۲.۱: ساختار شبکه عصبی.

[4]Multilayer Perceptron (MLP)

۳.۱.۱ توابع فعال‌سازی

توابع فعال‌سازی مسئولیت معرفی غیرخطی‌بودن به شبکه را بر عهده دارند. بدون این توابع، یک شبکه عمیق صرفاً یک تبدیل خطی بزرگ بود. توابعی مانند ReLU به دلیل خاصیت مشتق‌پذیری در دامنه‌های مثبت و کمک به کاهش مشکل محو شدگی گرادیان، به‌طور گسترده استفاده می‌شوند.

۴.۱.۱ آموزش و بهینه‌سازی

فرآیند آموزش، بهینه‌سازی پارامترهای $\theta = \{W, b\}$ برای حداقل‌سازی تابع هزینه $J(\theta)$ است. این کار معمولاً از طریق الگوریتم پس‌انتشار خطا[۵]و روش‌های مبتنی بر گرادیان تصادفی[۶]انجام می‌شود تا شبکه قادر به تعمیم‌دهی بر روی داده‌های دیده‌نشده باشد.

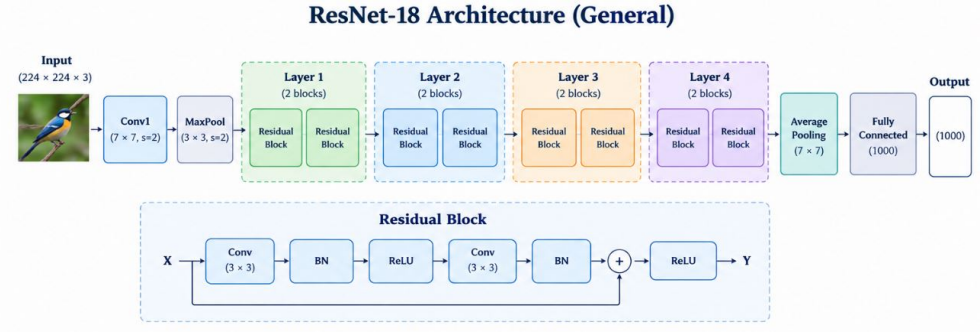
۵.۱.۱ شبکه ResNet-18

ResNet-18 یکی از معماری‌های شبکه‌های عصبی عمیق و عضوی از خانواده شبکه‌های باقیمانده[۷] است که با هدف تسهیل آموزش شبکه‌های عمیق معرفی شد [۱۴]. ایده اصلی این معماری استفاده از بلوک‌های باقیمانده است. در هر بلوک، ورودی علاوه بر عبور از چند لایه پردازشی، از طریق یک مسیر میان‌بُر[۸] نیز مستقیماً به خروجی منتقل می‌شود. سپس خروجی دو مسیر با یکدیگر ترکیب می‌شود. در نتیجه، شبکه به جای یادگیری یک تبدیل کاملاً جدید برای هر بلوک، می‌تواند تغییر موردنیاز نسبت به ورودی را یاد بگیرد. این ساختار همچنین مسیر مستقیمی برای عبور اطلاعات و گرادیان ایجاد می‌کند و به آموزش شبکه‌های عمیق کمک می‌کند.

ResNet-18 از چندین بلوک باقیمانده تشکیل شده است که به صورت متوالی قرار گرفته‌اند. با عبور داده از این بلوک‌ها، ویژگی‌های ورودی به تدریج پردازش و به نمایش‌های سطح بالاتر تبدیل می‌شوند. در بخش‌های ابتدایی شبکه، ویژگی‌های ساده‌تر استخراج می‌شوند و در بخش‌های

[5] Backpropagation
[6] Stochastic Gradient Descent
[7] Residual Networks (ResNet)
[8] Skip Connection

عمیق‌تر، ترکیب این ویژگی‌ها امکان یادگیری الگوهای پیچیده‌تر را فراهم می‌کند. در انتهای شبکه، ویژگی‌های استخراج‌شده به یک نمایش فشرده تبدیل شده و برای انجام وظیفه موردنظر، مانند طبقه‌بندی، مورد استفاده قرار می‌گیرند. عدد ۱۸ در نام این معماری به تعداد لایه‌های قابل یادگیری آن اشاره دارد.



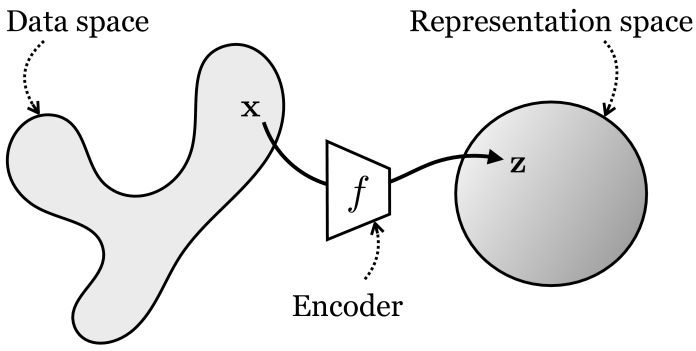
شکل ۱.۳: ساختار شبکه ResNet-18.
از ابزار مولد ChatGPT صرفا جهت تولید بصری این تصویر استفاده شده است.
تمامی ورودی‌ها توسط نویسنده تنظیم و خروجی مورد تایید است.

۲.۱ بازنمایی در شبکه‌های عصبی

۱.۲.۱ مفهوم بازنمایی

بازنمایی[9] به نگاشت داده‌ها از فضای ویژگی اولیه به یک فضای نهان[10] اشاره دارد که در آن الگوهای داده با تفکیک‌پذیری بیشتری ظاهر می‌شوند. هدف اصلی یادگیری عمیق، یافتن بازنمایی‌های مفید است به‌طوری که وظایف طبقه‌بندی یا رگرسیون تسهیل گردند [۱۱].

[9] Representation
[10] Latent Space



شکل ۴.۱: فضای بازنمایی [۱۲].

۲.۲.۱ یادگیری سلسله‌مراتبی ویژگی‌ها

شبکه‌های عصبی در طول لایه‌های خود، بازنمایی‌ها را به‌صورت سلسله‌مراتبی تکامل می‌دهند. لایه‌های ابتدایی معمولاً ویژگی‌های محلی (مانند لبه‌ها و بافت‌ها) را استخراج می‌کنند، در حالی که لایه‌های عمیق‌تر به ترکیب این ویژگی‌ها پرداخته و مفاهیم انتزاعی و معنایی[۱۱] سطح بالا را بازنمایی می‌کنند.

۳.۱ فاز پایانی آموزش

پاپیان[۱۲] و همکاران [۷] بازه‌ای از زمان را در طول فرآیند آموزش تعریف می‌کنند که فاز پایانی آموزش[۱۳] نامیده می‌شود. این فاز پس از آن آغاز می‌شود که خطای طبقه‌بندی مدل به صفر رسیده است (مدل تمامی داده‌های آموزشی را صحیح طبقه‌بندی می‌کند)، اما تابع هزینه همچنان به کاهش خود ادامه می‌دهد.

[11] Semantic
[12] Papyan
[13] Terminal Phase of Training (TPT)

۴.۱ سادک

سادک[14] یکی از مفاهیم پایه در هندسه است و می‌توان آن را تعمیمی از اشکال ساده‌ای مانند پاره‌خط، مثلث و چهاروجهی به فضاهای با بُعد بالاتر دانست. به‌طور کلی، یک kـسادک از $k+1$ نقطه تشکیل می‌شود که به‌صورت افاین مستقل[15] باشند؛ یعنی هیچ‌یک از این نقاط را نتوان به‌صورت ترکیب افاین سایر نقاط بیان کرد.

برای نمونه:

- یک ۱ـسادک یک پاره‌خط است که توسط دو نقطه تعیین می‌شود؛
- یک ۲ـسادک یک مثلث است که توسط سه نقطه‌ی غیرهم‌خط تشکیل می‌شود؛
- یک ۳ـسادک یک چهاروجهی است که توسط چهار نقطه‌ی غیرهم‌صفحه تعیین می‌شود.

به‌طور کلی، اگر نقاط $v_0, v_1, \ldots, v_k \in \mathbb{R}^d$ افاین مستقل باشند، آنگاه پوش محدب[16] این نقاط یک kـسادک را تشکیل می‌دهد:

$$\operatorname{conv}\{v_0, v_1, \ldots, v_k\} = \left\{ \sum_{i=0}^{k} \lambda_i v_i \;\middle|\; \lambda_i \geq 0,\ \sum_{i=0}^{k} \lambda_i = 1 \right\}. \qquad (1.1)$$

.

حالت ویژه‌ای از این مفهوم، **سادک منظم** است. در یک سادک منظم، فاصله‌ی بین هر دو رأس برابر است. این ویژگی نوعی تقارن هندسی ایجاد می‌کند و باعث می‌شود رأس‌ها به‌صورت یکنواخت در فضا توزیع شوند.

اگر مجموعه‌ای از بردارهای واحد $\{u_1, u_2, \ldots, u_C\}$ یک سادک منظم را تشکیل دهند،

[14] Simplex
[15] Affinely Independent
[16] Convex Hull

آنگاه ضرب داخلی هر دو بردار متمایز مقداری ثابت خواهد داشت:

$$u_i^\top u_j = \begin{cases} ۱, & i = j, \\ -\frac{۱}{C-۱}, & i \neq j. \end{cases} \quad (۲.۱)$$

.

این رابطه بیان می‌کند که زاویه‌ی بین هر دو بردار متمایز یکسان است. از این‌رو، سادک منظم نمونه‌ای از یک آرایش متقارن و یکنواخت از نقاط در فضا به شمار می‌آید.

۵.۱ کرنل

در بسیاری از کاربردهای یادگیری ماشین، تحلیل داده‌ها در فضای ویژگی اولیه دشوار است. توابع کرنلی[۱۷] ابزاری قدرتمند برای انتقال داده‌ها به فضاهای با ابعاد بالا فراهم می‌کنند که در آن روابط پیچیده به سادگی قابل تحلیل باشند.

۱.۵.۱ توابع کرنل

یک تابع کرنل $k(x, x')$ نگاشتی است که شباهت بین دو نمونه x و x' را در یک فضای ویژگی با ابعاد بالا (یا حتی نامتناهی) محاسبه می‌کند، بدون آنکه نیاز باشد مختصات نقاط در آن فضا صریحاً محاسبه شود. اگر $\phi(x)$ نگاشتی به فضای ویژگی باشد، تابع کرنل به‌صورت زیر تعریف می‌شود:

$$k(x, x') = \langle \phi(x), \phi(x') \rangle.$$

از ویژگی‌های اصلی یک تابع کرنل معتبر، متقارن بودن و نیمه‌معین مثبت[۱۸] بودن ماتریس کرنل

[17] Kernel

[18] Positive Semi-definite

(ماتریس گِرَم[19]) است. ماتریس گرم K برای مجموعه‌ای از n داده به‌صورت $K_{ij} = k(x_i, x_j)$ تعریف می‌شود.

۲.۵.۱ کرنل خطی و کرنل تابع پایه‌ی شعاعی

دو مورد از پرکاربردترین کرنل‌ها در تحلیل بازنمایی‌ها عبارتند از:

- **کرنل خطی:** ساده‌ترین نوع کرنل که ضرب داخلی مستقیم داده‌ها را محاسبه می‌کند:

$$k(x, x') = x^\top x'.$$

- **کرنل تابع پایه شعاعی گاوسی**[20] که برای مدل‌سازی روابط غیرخطی استفاده می‌شود:

$$k(x, x') = \exp(-\frac{\|x - x'\|^2}{2\sigma^2}).$$

۳.۵.۱ معیار استقلال هیلبرت‌ـاشمیت

معیار هیلبرت‌ـاشمیت[21] یک روش آماری برای سنجش وابستگی[22] بین دو مجموعه متغیر تصادفی X و Y است. این معیار بر پایه تئوری فضای هیلبرت با کرنل بازتولیدکننده[23] استوار است. به زبان ساده، HSIC میزان همبستگی بین ویژگی‌های استخراج شده از X (توسط کرنل K) و ویژگی‌های استخراج شده از Y (توسط کرنل L) را اندازه می‌گیرد.

برای دو ماتریس کرنل K و L که از n نمونه به‌دست آمده‌اند، تخمین‌گر HSIC به‌صورت زیر

[19] Gram Matrix
[20] Gaussian Radial Basis (RBF)
[21] Hilbert Schmidt Independence Criterion (HSIC)
[22] Dependency
[23] RKHS

تعریف می‌شود:

$$\mathrm{HSIC}(K, L) = \frac{۱}{(n-۱)^۲}\mathrm{tr}(KHLH) \qquad (۳.۱)$$

، که در آن $H = I - \frac{۱}{n}\mathbf{۱}\mathbf{۱}^\top$ ماتریس مرکزساز[۲۴] است. مقدار HSIC برابر با صفر به معنای استقلال کامل دو متغیر (در فضای نگاشت شده توسط کرنل) است و مقادیر بزرگتر نشان‌دهنده وابستگی بیشتر هستند.

۴.۵.۱ تراز کرنل

تراز کرنل[۲۵] مفهومی است که شباهت بین دو ماتریس کرنل را می‌سنجد. این ایده بیان می‌کند که اگر دو بازنمایی مختلف از داده‌ها، روابط ساختاری مشابهی را حفظ کرده باشند (یعنی جفت‌داده‌هایی که در فضای اول به هم نزدیکند، در فضای دوم نیز نزدیک باشند)، ماتریس‌های کرنل آن‌ها باید با هم هم‌ترازی بالایی داشته باشند. این مفهوم زیربنای اصلی معرفی معیار CKA در تحلیل شبکه‌های عصبی است.

[24] Centering Matrix

[25] Kernel Alignment

فصل ۲

پیشینه و مرور ادبیات

۱.۲ یادگیری بازنمایی در شبکه‌های عصبی عمیق

یادگیری بازنمایی[1] یکی از مفاهیم بنیادین در شبکه‌های عصبی عمیق است. برخلاف رویکردهای کلاسیک که متکی بر استخراج ویژگی‌های دست‌ساز هستند، شبکه‌های عمیق به‌صورت خودکار دنباله‌ای از بازنمایی‌های میانی را می‌آموزند که به‌تدریج داده‌ی ورودی را به شکلی مناسب‌تر برای انجام وظیفه‌ی مورد نظر تبدیل می‌کند. در مسائل طبقه‌بندی، هدف صرفاً نگاشت ورودی به برچسب[2] نیست، بلکه ساختن فضایی از ویژگی‌ها است که در آن نمونه‌های متعلق به کلاس‌های مختلف به‌صورت مؤثرتری از یکدیگر تفکیک شوند.

از دیدگاه هندسی، می‌توان داده‌های ورودی را به‌عنوان نقاطی روی یک خمینه‌ی پیچیده[3] و با بُعد بالا در نظر گرفت. با عبور داده از لایه‌های متوالی شبکه، هر لایه یک تبدیل خطی[4] به همراه یک تابع غیرخطی اعمال می‌کند و بدین ترتیب خمینه‌ی داده را به‌صورت لایه‌به‌لایه دگرگون می‌سازد. لایه‌های ابتدایی معمولاً الگوهای ساده و عمومی مانند لبه‌ها، بافت‌های محلی یا همبستگی‌های

[1] Representation Learning
[2] Label
[3] Manifold
[4] Affine

پایه[5] را استخراج می‌کنند، در حالی‌که لایه‌های عمیق‌تر ساختارهای انتزاعی‌تر و وابسته به مسئله را کدگذاری می‌کنند. این تحول سلسله‌مراتبی اغلب منجر به کاهش پراکندگی درون‌کلاسی و افزایش جدایی بین‌کلاسی می‌شود [۲].

این تفسیر لایه‌ای از یادگیری بازنمایی از منظرهای مختلفی مورد مطالعه قرار گرفته است. یکی از رویکردهای مهم، تحلیل شبکه‌های عمیق از دیدگاه هندسی و توپولوژیک است. نایتزات[6] و همکاران [۱] نشان می‌دهند که شبکه‌های عصبی می‌توانند داده‌ای با ساختار توپولوژیک پیچیده را در طی عبور از لایه‌ها به ساختاری ساده‌تر تبدیل کنند. در این چارچوب، عمق شبکه این امکان را فراهم می‌کند که تغییرات توپولوژیک و هندسی به‌صورت تدریجی در طول لایه‌ها توزیع شوند، و توابع فعال‌سازی غیرخطی نقش کلیدی در ایجاد این تحولات ایفا می‌کنند. این نتایج نشان می‌دهد که یادگیری عمیق صرفاً استخراج ویژگی نیست، بلکه بازآرایی هندسی و در برخی موارد توپولوژیک داده نیز محسوب می‌شود.

دیدگاه مکمل دیگر از حوزه‌ی یادگیری خمینه و کاهش بُعد نشأت می‌گیرد. روش‌های کلاسیکی مانند تحلیل مؤلفه‌های اصلی[7] و نگاشت‌های طیفی با هدف کشف ساختار کم‌بُعد در داده‌های با بُعد بالا توسعه یافته‌اند. این چارچوب‌ها شهودی هندسی برای درک بازنمایی‌های آموخته‌شده در شبکه‌های عمیق فراهم می‌کنند. در بسیاری از موارد، فضای ویژگی حاصل از یک شبکه‌ی آموزش‌دیده را می‌توان به‌گونه‌ای تفسیر کرد که گویی خمینه‌ی اولیه‌ی داده «بازشده» یا «تخت‌تر» شده و به حالتی درآمده است که جداسازی خطی در آن راحت‌تر است [۲]. این امر انگیزه‌ای برای استفاده از ابزارهای هندسی جهت تحلیل تحول بازنمایی‌ها در طول آموزش فراهم می‌کند.

یادگیری بازنمایی همچنین از طریق سنجش شباهت بین لایه‌ها و مدل‌ها قابل مطالعه است. کورنبلث[8] و همکاران [۳] معیار CKA را به‌عنوان روشی پایدار برای مقایسه‌ی بازنمایی‌های شبکه‌های عصبی معرفی کردند. CKA امکان مقایسه‌ی بازنمایی‌های تولیدشده در لایه‌های مختلف یا حتی مدل‌های متفاوت را فراهم می‌سازد و بدین ترتیب می‌توان بررسی کرد که چگونه اطلاعات

[5] Correlation
[6] Naitzat
[7] Principal Component Analysis(PCA)
[8] Kornblith

در طول عمق شبکه تحول می‌یابد. این ابزار به‌ویژه برای تحلیل پویایی بازنمایی‌ها در طی فرایند آموزش مفید است.

از سوی دیگر، برخی پژوهش‌ها یادگیری بازنمایی در شبکه‌های عمیق را با نظریه‌ی کرنل‌ها مرتبط ساخته‌اند. آنسلمی[9] و همکاران [۴] نشان می‌دهند که شبکه‌های کانولوشنی عمیق[10] را می‌توان به‌عنوان ماشین‌های کرنلی سلسله‌مراتبی در نظر گرفت که در هر لایه بازنمایی‌هایی با درجه‌ی بیشتری از ناوردا بودن و انتخاب‌گری ایجاد می‌کنند. این دیدگاه پلی میان روش‌های کلاسیک مبتنی بر کرنل و یادگیری عمیق مدرن برقرار می‌کند و بیان می‌کند که شبکه‌های عمیق با یادگیری نگاشت‌های ویژگی غنی، رفتارهایی مشابه کرنل‌های مناسب در فضای بازنمایی القا می‌کنند.

در مجموع، یادگیری بازنمایی در شبکه‌های عصبی عمیق را می‌توان به‌عنوان فرایندی از تحولات هندسی پی‌درپی در نظر گرفت که طی آن داده‌ی ورودی به فضایی منتقل می‌شود که برای انجام وظیفه‌ی نهایی مناسب‌تر است. هر لایه با بازشکل‌دهی خمینه‌ی داده، جداسازی بین کلاس‌ها را افزایش داده و ساختار بازنمایی را ساده‌تر و سازمان‌یافته‌تر می‌کند. این تفسیر هندسی مبنای مفهومی بخش‌های بعدی این فصل، به‌ویژه در زمینه‌ی سنجش شباهت بازنمایی‌ها، تحلیل‌های مبتنی بر کرنل، و پدیده‌ی فروپاشی عصبی را فراهم می‌سازد.

۲.۲ سنجش شباهت بازنمایی‌ها

برای درک نحوه‌ی تکامل بازنمایی‌ها در طول آموزش شبکه‌های عصبی عمیق، باید بتوانیم شباهت بین لایه‌های مختلف، یا یک لایه‌ی مشابه در دوره‌های[11] مختلف آموزش را کمی‌سازی کنیم. مقایسه‌ی این فضاهای با ابعاد بالا، چالش‌های ریاضی منحصربه‌فردی را ایجاد می‌کند.

[9] Anselmi

[10] Convolutional Deep Networks

[11] Epochs

۳.۲ مسئله‌ی هم‌ترازی

در یادگیری عمیق، مقایسه‌ی بردارهای فعال‌سازی[۱۲] خامِ دو لایه‌ی متفاوت ، یا حتی دو شبکه‌ی یکسان که با مقداردهی‌های اولیه‌ی تصادفی مختلف آموزش دیده‌اند ، عموماً فاقد اطلاعات مفید است. به دلیل وجود تقارن‌های جایگشتی ذاتی در معماری شبکه‌ها، نورون‌ها در یک لایه به‌طور طبیعی با نورون‌های لایه‌ی دیگر به‌صورت یک‌به‌یک هم‌تراز[۱۳] نمی‌شوند. علاوه بر این، شبکه‌ها می‌توانند بازنمایی‌های عملکردی یکسانی را یاد بگیرند که در محورهای (نورون‌های) خاص خود به‌طور کاملاً متفاوتی توزیع شده‌اند. بنابراین، یک معیار شباهت قوی باید ساختار هندسی زیربنایی بازنمایی‌ها را ارزیابی کند، نه فعال‌سازی‌های خام و عنصری[۱۴].

۴.۲ تحلیل همبستگی کانونی

یک رویکرد آماری کلاسیک برای این مسئله‌ی هم‌ترازی، تحلیل همبستگی کانونی[۱۵] است. با داشتن دو مجموعه‌ماتریس فعال‌سازی با میانگین صفر، $X \in \mathbb{R}^{n \times d_1}$ و $Y \in \mathbb{R}^{n \times d_2}$ (که در آن n تعداد نقاط داده و d_1, d_2 تعداد نورون‌ها هستند)، CCA به دنبال ترکیبات خطی از ستون‌های X و Y است که بیشترین همبستگی را با یکدیگر دارند.

از نظر ریاضی، CCA بردارهای وزن w_x و w_y را به‌گونه‌ای می‌یابد که ضریب همبستگی ρ را بیشینه کند:

$$\rho = \max_{w_x, w_y} \frac{w_x^T \Sigma_{xy} w_y}{\sqrt{w_x^T \Sigma_{xx} w_x} \sqrt{w_y^T \Sigma_{yy} w_y}} \quad ,$$

که در آن Σ_{xx} و Σ_{yy} ماتریس‌های کوواریانس تجربی X و Y، و Σ_{xy} ماتریس کوواریانس متقاطع است.

تلاش‌های اولیه برای مطالعه‌ی پویایی بازنمایی‌ها در یادگیری عمیق به‌شدت به CCA متکی

[12] Activation
[13] Align
[14] Element-wise
[15] Canonical Correlation Analysis (CCA)

بود. در یک پژوهش روش CCA بردار تکین[16] را معرفی کردند [۵] که ابتدا با انجام تجزیه مقادیر تکین[17]، پیش از اعمال CCA، جهت‌های نویزی را حذف می‌کند. در ادامه‌ی این مسیر، در تحقیقی روش CCA وزن‌دار با تصویر[18] را پیشنهاد دادند [۶] که جهت‌های CCA را بر اساس میزان تبیین خروجی‌های اصلی شبکه وزن‌دهی می‌کند و در نتیجه، معیاری قوی‌تر برای مقایسه‌ی لایه‌های شبکه ارائه می‌دهد.

۵.۲ محدودیت‌های CCA در یادگیری عمیق

علی‌رغم اهمیت تاریخی، CCA دارای محدودیت‌های بنیادینی است که آن را برای تحلیل‌های مدرن و با ابعاد بالای یادگیری عمیق نامناسب می‌سازد.

نقص اصلی، ویژگی‌های ناوردایی[19] آن است. CCA نسبت به هر تبدیل خطی وارون‌پذیر ناوردا است. اگر A و B هر ماتریس دارای رتبه کامل باشند، شباهت CCA بین X و Y با شباهت بین XA و YB یکسان است. اگرچه ناوردایی نسبت به چرخش در یادگیری عمیق بسیار مطلوب است، اما ناوردایی نسبت به *تمام* تبدیل‌های خطی وارون‌پذیر، بیش از حد سخت‌گیرانه است [۳]. این بدان معناست که CCA مقیاس‌گذاری همسانگرد[20] جهت‌های متعامد را نادیده می‌گیرد و مولفه‌های اصلی با واریانس بسیار زیاد را دقیقاً مشابه مولفه‌هایی با واریانس نزدیک به صفر در نظر می‌گیرد.

علاوه بر این، CCA از مشکل جدی ابعاد رنج می‌برد. زمانی که تعداد نورون‌ها (ابعاد) در یک لایه از تعداد نقاط داده در دسته‌ی[21] تحلیل‌شده بیشتر شود ($d_1, d_2 > n$)، CCA می‌تواند به‌راحتی ترکیبات خطی‌ای را بیابد که نویز تصادفی را به‌طور کامل هم‌تراز کنند. در این شرایط، امتیاز شباهت به سادگی به عدد ۱.۰ می‌گراید و این معیار را برای لایه‌های عریض یا اندازه‌های دسته‌ی کوچک بی‌فایده می‌سازد.

[16] SVCCA
[17] SVD
[18] PWCCA
[19] Invariance
[20] Isotropic Scaling
[21] Batch

۶.۲ گذار به هم‌ترازی کرنل مرکزی

از آنجا که CCA نسبت به ابعاد بیش‌ازحد حساس است و ناوردایی‌هایی را اعمال می‌کند که برای ویژگی‌های شبکه‌های عصبی بسیار گسترده هستند، محققان به معیاری نیاز داشتند که به‌طور موثر مقیاس‌پذیر باشد و شباهت ساختاری معناداری را ثبت کند. این نیاز منجر به پذیرش هم‌ترازی کرنل مرکزی[۲۲] شد [۳]. CKA با مقایسه‌ی ماتریس‌های گِرَم بازنمایی‌ها به‌جای هم‌تراز کردن مستقیم فضاهای برداری آن‌ها، از گلوگاه‌های ابعادی CCA عبور کرده و مجموعه‌ای از ناوردایی‌های مناسب‌تر (تبدیل متعامد و مقیاس‌گذاری همسانگرد) را اعمال می‌کند. فرمول‌بندی CKA در بخش بعدی به‌طور دقیق تشریح شده است.

۷.۲ هم‌ترازی کرنل مرکزی

برای رفع محدودیت‌های CCA در محیط‌های با بُعد بالا، معیار هم‌ترازی کرنل مرکزی به‌عنوان معیاری قوی‌تر برای مقایسه‌ی بازنمایی‌های شبکه‌های عصبی معرفی شد [۳]. برخلاف CCA که تلاش می‌کند زیرفضای خطی مشترکی را بیابد، CKA بر رابطه‌ی بین ماتریس‌های شباهت بازنمایی‌ها تمرکز دارد و معیاری پایدار ارائه می‌دهد که در معماری‌ها و مقداردهی‌های اولیه متفاوت، سازگار است.

۸.۲ ماتریس گِرَم و شباهت

با داشتن ماتریس بازنمایی $X \in \mathbb{R}^{n \times d}$، ماتریس گِرَم $K = XX^\top$ را تعریف می‌کنیم. هر درایه $K_{ij} = x_i^\top x_j$ نمایانگر حاصل‌ضرب داخلی (شباهت) بین نمونه‌ی iـام و jـام است. این ماتریس ساختار هندسی بازنمایی را در بر می‌گیرد و نسبت به تبدیل‌های متعامد ناوردا است و تنها به فاصله‌ی نسبی نقاط داده بستگی دارد. در صورت استفاده از کرنل‌های غیرخطی (مانند تابع پایه‌شعاعی)، ماتریس K روابط پیچیده‌تر و غیرخطی را ثبت می‌کند.

[22] Centered Kernel Alignment (CKA)

۹.۲ تعریف CKA

CKA شباهت بین دو ماتریس بازنمایی X و Y را با مقایسه‌ی ماتریس‌های گِرَم متناظر آن‌ها، یعنی $K = XX^\top$ و $L = YY^\top$، اندازه‌گیری می‌کند. برای اطمینان از اینکه این معیار نسبت به مقیاس‌گذاری ایستا ناوردا بوده و بر هم‌ترازی ساختارهای بازنمایی تمرکز کند، از ماتریس‌های گِرَم مرکززدایی‌شده استفاده می‌شود:

$$K' = HKH, \quad L' = HLH,$$

که در آن $H = I - \frac{۱}{n}\mathbf{۱}\mathbf{۱}^\top$ ماتریس مرکززدایی است. سپس CKA به‌صورت معیار استانداردشده‌ی «معیار استقلال هیلبرت–اشمیت» (HSIC) تعریف می‌شود:

$$\mathrm{CKA}(K, L) = \frac{\mathrm{HSIC}(K, L)}{\sqrt{\mathrm{HSIC}(K, K)\mathrm{HSIC}(L, L)}},$$

که در آن $\mathrm{HSIC}(K, L) = \frac{۱}{(n-۱)^۲}\mathrm{Tr}(K'L')$ محاسبه می‌شود.

۱۰.۲ مزایا در تحلیل یادگیری عمیق

CKA چندین مزیت عملی برای تحلیل شبکه‌های عصبی عمیق ارائه می‌دهد:

- **مقاومت در برابر ابعاد بالا:** از آنجا که CKA ماتریس‌های شباهت $(n \times n)$ را مقایسه می‌کند، نه ویژگی‌ها $(d \times d)$، با محدودیت $d > n$ که CCA با آن مواجه است، درگیر نمی‌شود.
- **استقلال از معماری:** CKA می‌تواند لایه‌ها با تعداد نورون‌های متفاوت یا حتی معماری‌های مختلف را مقایسه کند، زیرا ماتریس‌های گِرَم صرفاً به تعداد نمونه‌ها (n) وابسته هستند.
- **پویایی آموزش:** CKA به‌طور قابل‌اطمینانی تناظرات بین لایه‌ها را در طول اجرای مستقل آموزش شناسایی می‌کند. این امر به محققان اجازه می‌دهد تا چگونگی همگرایی مدل‌های مختلف به ساختارهای بازنمایی مشابه را ردیابی کنند و بینش عمیقی نسبت به «مسیرهایی» که شبکه‌ها برای بهینه‌سازی طی می‌کنند، به دست آورند [۳].

با تمرکز بر چگونگی هم‌ترازی ساختارهای شباهت داخلی با یکدیگر، CKA به ابزاری استاندارد در پژوهش‌های یادگیری عمیق برای تفسیر تحول فضای ویژگی و سنجش تأثیر انتخاب‌های معماری بر رفتار مدل تبدیل شده است.

۱۱.۲ فروپاشی عصبی

پدیده‌ی فروپاشی عصبی[۲۳] به مجموعه‌ای از رفتارهای هندسی اشاره دارد که در مراحل پایانی آموزش شبکه‌های عصبی عمیق پدیدار می‌شوند. زمانی که خطای آموزش به صفر نزدیک می‌شود، نمایش‌های ویژگی و وزن‌های طبقه‌بند نهایی به ساختاری بسیار متقارن و ساده همگرا می‌شوند. در ادامه، چهار ویژگی اساسی این پدیده همراه با فرمول‌های دقیق آن را ارائه می‌کنیم [۷].

[23] Neural Collapse

فروپاشی درون‌کلاسی : NC1

$$\Sigma_W = ۰.$$

Σ_W ماتریس کوواریانس درون‌کلاسی است و توسط رابطهٔ زیر تعریف می‌شود:

$$\Sigma_W = \sum_{c=۱}^{C} \sum_{i \in S_c} (z_i - \mu_c)(z_i - \mu_c)^\top.$$

شرط $\Sigma_W = ۰$ بیانگر آن است که تمام بردارهای ویژگی یک کلاس دقیقاً روی میانگین همان کلاس قرار می‌گیرند:

$$z_i = \mu_c \quad \text{برای تمام} i \in S_c.$$

هر کلاس در فضای ویژگی‌ها تبدیل به یک نقطه می‌شود. هیچ پراکندگی درون‌کلاسی وجود ندارد؛ همهٔ نمونه‌های کلاس c به μ_c نگاشت می‌شوند.

ساختار سادک چارچوب تنگ هم‌زاویه : NC2

خاصیت سادک چارچوب تنگ هم‌زاویه[۲۴] بیان می‌کند که میانگین کلاس‌ها به بیشترین میزان ممکن از هم فاصله می‌گیرند و به شکل یک سادک منتظم و کاملاً متقارن در فضا قرار می‌گیرند. این ویژگی شامل دو بخش است.

(الف) برابر بودن فاصله از میانگین کلی

$$\|\mu_c - \mu_G\|_۲ = \|\mu_{c'} - \mu_G\|_۲ \qquad \forall c, c'.$$

[24] Equiangular Tight Frame (ETF)

تمام میانگین‌های کلاسی روی کره‌ای به مرکز میانگین کلی قرار می‌گیرند:

$$\mu_G = \frac{1}{C} \sum_{c=1}^{C} \mu_c.$$

از آن‌جایی که میانگین‌های کلاسی روی یک کره قرار می‌گیرند، همهٔ کلاس‌ها دارای یک اندازه[25] برابر هستند. این اولین شرط برای تشکیل یک سادک منتظم است.

(ب) برابر بودن زاویهٔ بین میانگین کلاس‌ها

$$\langle \tilde{\mu}_c, \tilde{\mu}_{c'} \rangle = \frac{C}{C-1} \delta_{c,c'} - \frac{1}{C-1},$$

که در آن

$$\tilde{\mu}_c = \frac{\mu_c - \mu_G}{\|\mu_c - \mu_G\|_2},$$

میانگین‌های نرمال‌سازی‌شده و مرکززدایی‌شدهٔ کلاس‌ها هستند و $\delta_{c,c'}$ دلتای کرونکر[26] است.

- اگر $c = c'$ باشد: ضرب داخلی برابر ۱ است در نتیجه هر بردار طول واحد دارد.
- اگر $c \neq c'$ باشد:

$$\langle \tilde{\mu}_c, \tilde{\mu}_{c'} \rangle = -\frac{1}{C-1},$$

و زاویهٔ بین تمام کلاس‌ها یکسان است.

این دقیقاً ویژگی یک **سادک منتظم** است: کلاس‌ها حداکثر جدایش و حداکثر تقارن ممکن را دارند.

[25] Norm
[26] Kronecker

خود دوگانگی (هم‌راستایی وزن‌ها و میانگین کلاس‌ها) : NC3

$$\frac{W^\top}{\|W\|_F} = \frac{\tilde{M}}{\|\tilde{M}\|_F}.$$

در این رابطه:

- $W = [\, w_1, \ldots, w_C \,]$ ماتریس وزن‌های طبقه‌بند است.
- $\tilde{M} = [\, \mu_c - \mu_G : c = 1, \ldots, C \,]$ ماتریس میانگین‌های مرکززدایی‌شده است.

خود دوگانگی[۲۷] بیان می‌کند که وزن‌های طبقه‌بند و میانگین‌های کلاس ساختار هندسي مشابه دارند. طبقه‌بند یاد مي‌گیرد تا به جهت میانگین کلاس‌ها اشاره کند.

طبقه‌بند دقیقاً همان شکل هندسی میانگین کلاس‌ها را بازتولید می‌کند. هر بردار وزن طبقه بند w_c با میانگین کلاس μ_c هم‌راستا می‌شود. ماتریس وزن‌ها نیز یک سادک می‌سازد که انعکاسی از همان سادک میانگین کلاس‌ها است. به همین دلیل به این ویژگی «خود دوگانگی» گفته می‌شود.

معادل شدن رفتار طبقه‌بند با نزدیک‌ترین مرکز کلاس : NC4

$$\arg\max_{c'} \langle w_{c'}, h \rangle + b_{c'} = \arg\min_{c'} \| h - \mu_{c'} \|_2.$$

در فروپاشی عصبی، طبقه‌بند خطی استاندارد دقیقاً همان پیش‌بینی‌ای را انجام می‌دهد که قانون «نزدیک‌ترین میانگین کلاس» انجام می‌دهد.

به‌دلیل:

- تقارن سیمپلکس (از NC2)
- هم‌راستایی وزن‌ها با میانگین کلاس‌ها (از NC3)

[27] Self Duality

عمل طبقه‌بند ساده می‌شود به:

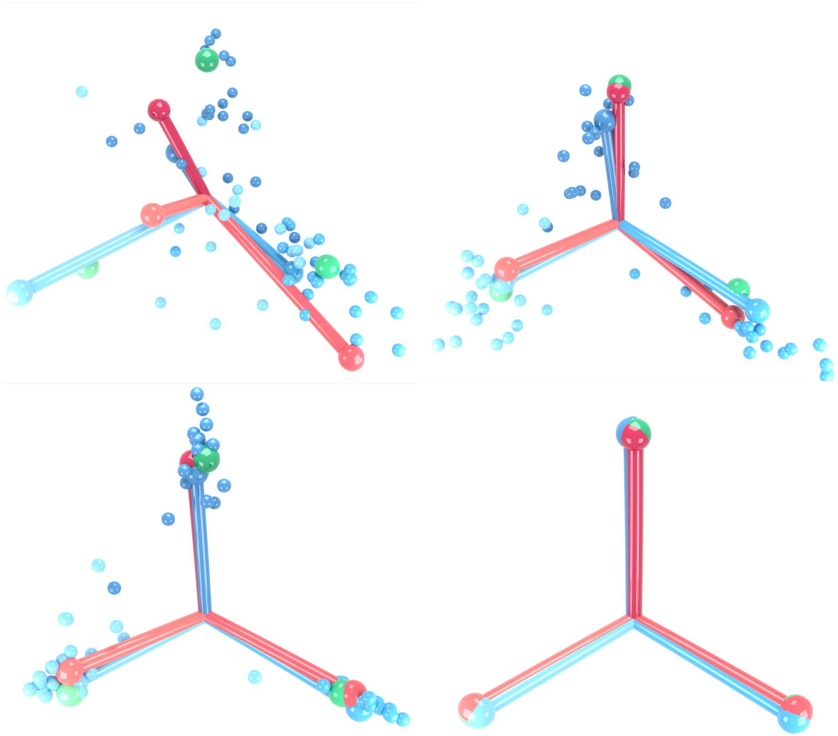
انتخاب نزدیک‌ترین میانگین کلاس

این رفتار بسیار ساده‌تر از یک طبقه‌بند خطی کلی است.

خلاصهٔ چهار ویژگی

- **NC1 :** تمام ویژگی‌های هر کلاس روی یک نقطه (میانگین کلاس) فرو می‌ریزند.
- **NC2 :** میانگین کلاس‌ها یک سادک منتظم تشکیل می‌دهند.
- **NC3 :** وزن‌های طبقه‌بند با میانگین‌های کلاس هم‌راستا می‌شوند.
- **NC4 :** طبقه‌بندی معادل «نزدیک‌ترین میانگین کلاس» می‌شود.

این چهار خاصیت نشان می‌دهند که نمایش شبکه در پایان آموزش به ساختاری بسیار متقارن و ساده همگرا می‌شود که درک هندسی عمیقی از رفتار مدل فراهم می‌کند.



شکل ۱.۲ : نمایش پدیده‌ی فروپاشی عصبی در طی فرایند آموزش شبکه (از چپ به راست) [۷].

فصل ۳

روش‌شناسی و طراحی آزمایش

۱.۳ چارچوب نظری

شبکه‌های عصبی عمیق در طول فرآیند آموزش، نمایش‌های سلسله‌مراتبی از داده‌ها را در لایه‌های مختلف خود یاد می‌گیرند. اگرچه عملکرد نهایی این شبکه‌ها از نظر تجربی به خوبی شناخته شده است، اما نحوه تکامل و همگرایی نمایش‌های داخلی آن‌ها همچنان یکی از موضوعات فعال پژوهشی در حوزه یادگیری عمیق به شمار می‌رود. در سال‌های اخیر، دو دیدگاه مکمل برای مطالعه این فرآیند ارائه شده است. دیدگاه نخست بر شباهت نمایش‌ها[1] تمرکز دارد و هدف آن اندازه‌گیری میزان تغییر یا پایداری نمایش‌های آموخته‌شده در طول آموزش است. دیدگاه دوم به بررسی هندسه نمایش‌های آموخته‌شده، به‌ویژه در مراحل پایانی آموزش، می‌پردازد که تحت عنوان پدیده فروپاشی عصبی شناخته می‌شود.

معیار CKA چارچوبی مناسب برای اندازه‌گیری شباهت بین نمایش‌های حاصل از لایه‌های مختلف، مدل‌های متفاوت یا نقاط زمانی مختلف در فرآیند آموزش فراهم می‌کند. این معیار با مقایسه ماتریس‌های گرم ساخته‌شده از بردارهای ویژگی، میزان شباهت دو نمایش را اندازه‌گیری می‌کند و نسبت به تبدیلات متعامد و تغییر مقیاس یکنواخت ناوردا است. از این رو، CKA ابزاری

[1] Representation Similarity

مناسب برای بررسی روند تکامل نمایش‌های داخلی شبکه و تعیین زمان پایداری آن‌ها محسوب می‌شود.

در مقابل، پدیده فروپاشی عصبی به ساختار هندسی نمایش‌های ویژگی در فاز نهایی آموزش می‌پردازد. در این مرحله، نمونه‌های متعلق به هر کلاس به سمت مرکز همان کلاس همگرا می‌شوند، مراکز کلاس‌ها به آرایش متقارن چارچوب تنگ هم‌زاویه نزدیک می‌شوند، وزن‌های لایه طبقه‌بندی با مراکز کلاس‌ها هم‌راستا می‌شوند و تصمیم‌گیری مدل به رفتار نزدیک‌ترین مرکز کلاس میل می‌کند. این ویژگی‌ها از طریق چهار معیار اصلی، با نام‌های $\mathrm{NC1}$ تا $\mathrm{NC4}$ اندازه‌گیری می‌شوند.

اگرچه CKA و فروپاشی عصبی جنبه‌های متفاوتی از فرآیند یادگیری نمایش را بررسی می‌کنند، هر دو بر پایه همان نمایش‌های ویژگی تولیدشده توسط شبکه تعریف می‌شوند. فرض کنید

$$\mathbf{H} \in \mathbb{R}^{n \times d},$$

ماتریس ویژگی استخراج‌شده از یک لایه مشخص شبکه باشد که در آن n تعداد نمونه‌ها و d بعد فضای ویژگی است.

بر اساس این ماتریس، ماتریس گرم به صورت زیر تعریف می‌شود:

$$\mathbf{K} = \mathbf{H}\mathbf{H}^{\top},$$

که عناصر آن حاصل‌ضرب داخلی بین بردارهای ویژگی نمونه‌ها را نشان می‌دهد. معیار CKA با مقایسه این ماتریس در نقاط مختلف آموزش، میزان شباهت نمایش‌های آموخته‌شده را اندازه‌گیری می‌کند.

از سوی دیگر، معیارهای فروپاشی عصبی از آماره‌های استخراج‌شده از همین ماتریس ویژگی استفاده می‌کنند. به طور خاص، ماتریس پراکندگی درون‌کلاسی به صورت

$$\mathbf{S}_W = \sum_{c=1}^{C} \sum_{i:y_i=c} (\mathbf{h}_i - \boldsymbol{\mu}_c)(\mathbf{h}_i - \boldsymbol{\mu}_c)^{\top},$$

و ماتریس پراکندگی بین‌کلاسی به صورت

$$\mathbf{S}_B = \sum_{c=1}^{C} (\boldsymbol{\mu}_c - \boldsymbol{\mu}_G)(\boldsymbol{\mu}_c - \boldsymbol{\mu}_G)^\top,$$

تعریف می‌شوند که در آن $\boldsymbol{\mu}_c$ میانگین ویژگی‌های کلاس c و $\boldsymbol{\mu}_G$ میانگین کل ویژگی‌ها است.

در نتیجه، در حالی که CKA میزان پایداری نمایش‌ها را در طول آموزش اندازه‌گیری می‌کند، معیارهای فروپاشی عصبی کیفیت ساختار هندسی همان نمایش‌ها را ارزیابی می‌کنند. بنابراین این دو رویکرد نه رقیب، بلکه مکمل یکدیگر هستند؛ CKA بیان می‌کند که نمایش‌ها تا چه اندازه به وضعیت نهایی خود نزدیک شده‌اند، در حالی که فروپاشی عصبی مشخص می‌کند آیا این نمایش‌های پایدار، ویژگی‌های هندسی مورد انتظار را نیز کسب کرده‌اند یا خیر.

فرضیه اصلی این پژوهش بر این اساس شکل گرفته است که میان پایداری نمایش‌ها و ظهور پدیده فروپاشی عصبی رابطه‌ای زمانی وجود دارد. اگر نمایش‌های داخلی شبکه پیش از پایان آموزش به حالت پایدار برسند، انتظار می‌رود ویژگی‌های هندسی فروپاشی عصبی نیز پس از آن یا هم‌زمان با آن ظاهر شوند. از سوی دیگر، اگر پدیده فروپاشی عصبی تنها پس از تثبیت نمایش‌ها رخ دهد، معیار CKA می‌تواند به عنوان شاخصی برای پیش‌بینی زمان ظهور فروپاشی عصبی مورد استفاده قرار گیرد.

به منظور بررسی این فرضیه، در این پژوهش مقدار CKA و چهار معیار اصلی فروپاشی عصبی برای مجموعه‌ای از نقاط زمانی یکسان در طول فرآیند آموزش محاسبه و روند تغییرات آن‌ها با یکدیگر مقایسه می‌شود. هدف نهایی، تعیین این موضوع است که آیا پایداری نمایش‌ها پیش از ظهور ویژگی‌های هندسی فروپاشی عصبی اتفاق می‌افتد، هم‌زمان با آن رخ می‌دهد یا پس از آن حاصل می‌شود. بر اساس چارچوب نظری ارائه‌شده، در این پژوهش تلاش می‌شود ارتباط زمانی میان پایداری نمایش‌های آموخته‌شده و ظهور ویژگی‌های هندسی فروپاشی عصبی به‌صورت تجربی مورد بررسی قرار گیرد. برای این منظور، مقادیر معیار CKA و چهار معیار اصلی فروپاشی عصبی در نقاط مختلف فرآیند آموزش یک شبکه عصبی عمیق محاسبه و روند تغییرات آن‌ها با یکدیگر مقایسه می‌شود. در بخش بعد، جزئیات مربوط به روش تحقیق، شامل معماری شبکه، مجموعه‌داده،

نحوه آموزش مدل، روش استخراج ویژگی‌ها و نحوه محاسبه معیارهای مورد استفاده، به‌طور کامل تشریح خواهد شد.

۲.۳ روش تحقیق

این پژوهش از نوع مطالعات تجربی است و با هدف بررسی ارتباط زمانی میان تغییرات بازنمایی‌های داخلی شبکه و شکل‌گیری ساختار هندسی مرتبط با پدیده فروپاشی عصبی انجام شده است. برای این منظور، فرآیند آموزش یک شبکه عصبی عمیق در نقاط زمانی مختلف بررسی و تغییرات بازنمایی‌های داخلی، معیارهای فروپاشی عصبی و عملکرد مدل در طول آموزش تحلیل شدند.

در این پژوهش از یک مدل ResNet-18 استفاده شد که بر روی مجموعه‌داده CIFAR-10 به مدت ۳۵۰ دوره آموزش داده شده است. وضعیت مدل در ۱۱۳ نقطه زمانی از فرآیند آموزش به صورت نقطه‌ی بازرسی[۲] ذخیره شد و در هر یک از این نقاط، معیارهای مورد نظر محاسبه شدند. استفاده از نقاط زمانی متعدد امکان بررسی روند تغییرات معیارها و تعیین زمان تثبیت آن‌ها را فراهم می‌کند.

برای بررسی تغییرات بازنمایی‌های داخلی، معیار CKA به صورت لایه‌ای محاسبه شد. در این تحلیل، بازنمایی‌های حاصل از لایه‌های Conv1 و Layer1-4 در هر نقطه زمانی با بازنمایی متناظر همان لایه در مدل نهایی، یعنی دوره ۳۵۰، مقایسه شدند. بنابراین، CKA میزان نزدیک شدن بازنمایی هر لایه به بازنمایی نهایی همان لایه را در طول آموزش نشان می‌دهد.

در مقابل، معیارهای NC1 تا NC4 بر اساس ویژگی‌های استخراج‌شده از خروجی لایه‌ی تجمع میانگین[۳] محاسبه شدند. این ویژگی‌ها برای هر نمونه به یک بردار ۵۱۲ بعدی تبدیل شده و برای بررسی ساختار هندسی فضای ویژگی مورد استفاده قرار گرفتند. بدین ترتیب، CKA برای بررسی پایداری بازنمایی در لایه‌های مختلف و معیارهای فروپاشی عصبی برای بررسی ساختار هندسی نمایش نهایی ویژگی‌ها به کار گرفته شدند.

[2] Checkpoint

[3] Average Pooling

علاوه بر این معیارها، دقت آموزش و تابع زیان آنتروپی متقاطع[4] نیز در طول فرآیند آموزش ثبت و تحلیل شدند. دقت آموزش برای تعیین زمان رسیدن مدل به عملکرد بسیار بالا و بررسی فاز پایانی آموزش مورد استفاده قرار گرفت، در حالی که تابع زیان اطلاعات بیشتری درباره میزان اطمینان مدل در پیش‌بینی کلاس صحیح ارائه می‌کند.

برای هر معیار، زمان تثبیت به صورت اولین نقطه زمانی تعریف شد که معیار به محدوده تعیین‌شده نسبت به مقدار نهایی خود برسد و این وضعیت را تا پایان آموزش حفظ کند. این تعریف امکان مقایسه زمانی میان تثبیت بازنمایی‌ها، شکل‌گیری ساختار هندسی ویژگی‌ها و رسیدن مدل به عملکرد نهایی را فراهم می‌کند.

۳.۳ مجموعه‌داده و پیش‌پردازش

در این پژوهش، از مجموعه‌داده استاندارد CIFAR-10 برای آموزش و ارزیابی مدل استفاده شده است. این مجموعه‌داده یکی از رایج‌ترین مجموعه‌داده‌ها در حوزه بینایی ماشین بوده و به دلیل اندازه مناسب، تنوع کلاس‌ها و استفاده گسترده در پژوهش‌های مرتبط با یادگیری عمیق، به عنوان یکی از معیارهای استاندارد ارزیابی الگوریتم‌های طبقه‌بندی تصویر شناخته می‌شود.

مجموعه‌داده CIFAR-10 شامل ۶۰۰۰۰ تصویر رنگی با ابعاد ۳۲×۳۲ پیکسل است که در ۱۰ کلاس مختلف توزیع شده‌اند. از این تعداد، ۵۰۰۰۰ تصویر برای آموزش و ۱۰۰۰۰ تصویر برای آزمون در نظر گرفته شده است. هر کلاس شامل ۶۰۰۰ تصویر بوده که ۵۰۰۰ نمونه در مجموعه آموزش و ۱۰۰۰ نمونه در مجموعه آزمون قرار دارند. کلاس‌های این مجموعه‌داده شامل هواپیما، خودرو، پرنده، گربه، گوزن، سگ، قورباغه، اسب، کشتی و کامیون هستند.

به منظور افزایش توانایی تعمیم مدل و کاهش بیش‌برازش، بر روی تصاویر مجموعه آموزش از تکنیک‌های افزایش داده[5] استفاده شده است. در این مرحله ابتدا تصاویر با استفاده از روش برش تصادفی[6] همراه با حاشیه چهار پیکسلی به صورت تصادفی برش داده شده و سپس با احتمال ۵۰

[4] Cross-Entropy Loss
[5] Data Augmentation
[6] Random Crop

درصد به صورت افقی قرینه[7] شده‌اند. پس از آن، تصاویر به تانسور[8] تبدیل شده و با استفاده از میانگین و انحراف معیار کانال‌های رنگی مجموعه‌داده نرمال‌سازی شده‌اند.

برای مجموعه آزمون، به منظور حفظ شرایط استاندارد ارزیابی، هیچ‌گونه عملیات افزایش داده اعمال نشده و تنها تبدیل تصاویر به تانسور و نرمال‌سازی انجام شده است.

مقادیر مورد استفاده برای نرمال‌سازی مطابق مقادیر استاندارد مجموعه‌داده CIFAR-10 به صورت زیر در نظر گرفته شده‌اند:

$$\boldsymbol{\mu} = (۰/۴۹۱۴,\ ۰/۴۸۲۲,\ ۰/۴۴۶۵),$$

$$\boldsymbol{\sigma} = (۰/۲۰۲۳,\ ۰/۱۹۹۴,\ ۰/۲۰۱۰).$$

با توجه به تفاوت ماهیت معیارهای مورد استفاده در این پژوهش، داده‌های مورد نیاز برای محاسبه آن‌ها نیز متفاوت انتخاب شده‌اند.

برای محاسبه معیارهای فروپاشی عصبی شامل NC1-4 از کل مجموعه آموزش استفاده شده است. در هر نقطه از فرآیند آموزش، ویژگی‌های استخراج‌شده از لایه‌ی تجمع میانگین برای تمامی ۵۰۰۰۰ نمونه آموزشی مورد استفاده قرار گرفته‌اند. این ویژگی‌ها دارای بعد ۵۱۲ بوده و به همراه برچسب‌های متناظر، مبنای محاسبه تمامی معیارهای فروپاشی عصبی قرار گرفته‌اند. استفاده از کل مجموعه آموزش موجب می‌شود میانگین کلاس‌ها، ماتریس‌های پراکندگی و سایر کمیت‌های هندسی با بیشترین دقت ممکن محاسبه شوند. از آنجا که مجموعه آموزش شامل ۱۰ کلاس با ۵۰۰۰ نمونه در هر کلاس است، تمامی محاسبات NC بر پایه این توزیع کامل انجام شده‌اند.

در مقابل، معیار CKA بر پایه مقایسه ماتریس‌های گرم محاسبه می‌شود و هزینه محاسباتی آن با افزایش تعداد نمونه‌ها به صورت درجه دوم رشد می‌کند. به همین دلیل، استفاده از تمامی نمونه‌های مجموعه آموزش یا آزمون هزینه محاسباتی و حافظه بسیار بالایی ایجاد می‌کند. به منظور کاهش این هزینه و در عین حال حفظ نمایندگی مناسب از داده‌ها، یک زیرمجموعه ثابت شامل ۱۰۰۰

[7] Random Horizontal Flip

[8] Tensor

تصویر از مجموعه آزمون انتخاب شد و در تمامی مراحل محاسبه CKA مورد استفاده قرار گرفت. استفاده از یک زیرمجموعه ثابت باعث می‌شود تغییرات مشاهده‌شده در مقدار CKA تنها ناشی از تغییر نمایش‌های شبکه در طول آموزش باشد و نه ناشی از تفاوت نمونه‌های ورودی.

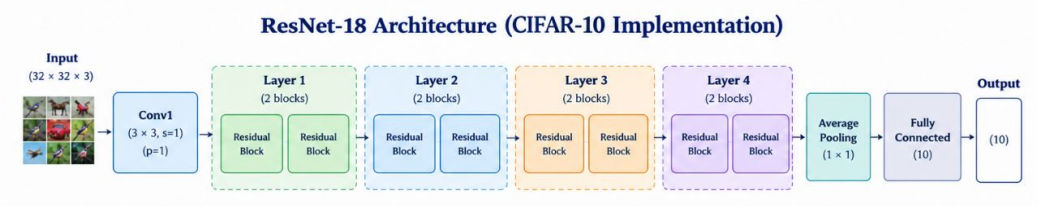
جدول ۱.۳ خلاصه داده‌های مورد استفاده برای محاسبه معیارهای مختلف را نشان می‌دهد.

جدول ۱.۳: خلاصه داده‌های مورد استفاده برای محاسبه معیارهای پژوهش.

معیار	مجموعه داده	تعداد نمونه
NC1 NC2 NC3 NC4	مجموعه آموزش	۵۰۰۰۰
CKA	زیرمجموعه ثابت از مجموعه آزمون	۱۰۰۰

۴.۳ معماری شبکه و تنظیمات آموزش

به منظور بررسی روند تکامل بازنمایی‌های داخلی شبکه در طول آموزش، از معماری ResNet-18 استفاده شد. این معماری از چهار مرحله اصلی با نام‌های Layer1 تا Layer4 تشکیل شده است که پس از لایه اولیه Conv1 قرار دارند. در این پژوهش، بازنمایی‌های این پنج بخش برای تحلیل تغییرات لایه‌ای با استفاده از معیار CKA مورد بررسی قرار گرفتند.



شکل ۱.۳: معماری ResNet-18 مورد استفاده در پژوهش برای مجموعه‌داده CIFAR-10.
از ابزار مولد ChatGPT صرفا جهت تولید بصری این تصویر استفاده شده است.
تمامی ورودی‌ها توسط نویسنده تنظیم و خروجی مورد تایید است.

از آنجا که معماری استاندارد ResNet-18 برای تصاویر با ابعاد بزرگ‌تر طراحی شده است،

برای استفاده از مجموعه‌داده CIFAR-10 با تصاویر ۳۲ × ۳۲ پیکسلی، تغییراتی در بخش ابتدایی شبکه اعمال شد. در نسخه مورد استفاده در این پژوهش، لایه کانولوشن اولیه با یک کانولوشن ۳ × ۳ با گام برابر با ۱ و حاشیه‌گذاری[9] برابر با ۱ جایگزین شد. همچنین، لایه اولیه تجمع بیشینه[10] حذف گردید تا از کاهش بیش از حد ابعاد فضایی ویژگی‌ها در مراحل ابتدایی شبکه جلوگیری شود. در نهایت، با توجه به وجود ۱۰ کلاس در مجموعه‌داده CIFAR-10، تعداد خروجی‌های لایهٔ کاملاً متصل[11] برابر با ۱۰ در نظر گرفته شد.

داده پس از عبور از لایه Conv1 به ترتیب از چهار مرحله Layer1، Layer2، Layer3 و Layer4 عبور می‌کند. در انتهای شبکه، خروجی لایه‌ی تجمع میانگین به عنوان نمایش ویژگی پیش از لایه طبقه‌بندی مورد استفاده قرار گرفت. این خروجی برای هر نمونه به یک بردار ویژگی ۵۱۲ بعدی تبدیل می‌شود و مبنای محاسبه معیارهای NC1 تا NC4 قرار گرفت. در مقابل، برای تحلیل CKA، خروجی هر یک از پنج بخش Conv1 تا Layer4 به صورت جداگانه استخراج و در طول آموزش با خروجی همان بخش در مدل نهایی مقایسه شد.

برای آموزش شبکه، از تابع هزینه آنتروپی متقاطع استفاده شد. بهینه‌سازی پارامترهای شبکه با الگوریتم گرادیان کاهشی تصادفی [12] همراه با مومنتوم[13] انجام شد. نرخ یادگیری اولیه برابر با ۰/۱، ضریب مومنتوم برابر با ۰/۹ و مقدار افول وزن[14] برابر با ۵×۱۰^{-۴} در نظر گرفته شد.

به منظور کاهش تدریجی نرخ یادگیری در طول آموزش، از زمان‌بند کاهش کسینوسی[15] استفاده شد. در این روش، نرخ یادگیری طی ۳۵۰ دوره آموزش از مقدار اولیه ۰/۱ به حداقل مقدار $۱۰^{-۵}$ کاهش یافت. مدل به مدت ۳۵۰ دوره آموزش داده شد و وضعیت آن در ۱۱۳ نقطه زمانی به صورت نقطه‌ی بازرسی ذخیره گردید.

تمامی آزمایش‌ها با استفاده از چارچوب PyTorch اجرا شدند. استخراج ویژگی‌ها و محاسبه

[9] Padding
[10] Max Pooling
[11] Fully Connected
[12] Stochastic Gradient Descent (SGD)
[13] Momentum
[14] Weight Decay
[15] Cosine Annealing

معیارهای مورد استفاده نیز در هر یک از نقاط ذخیره‌شده انجام گرفت.

۵.۳ استخراج ویژگی‌ها و محاسبه معیارها

در این پژوهش، نحوه استخراج ویژگی‌ها متناسب با نوع معیار مورد استفاده تعیین شد. برای تحلیل تغییرات بازنمایی‌های داخلی با استفاده از معیار CKA، خروجی لایه‌های Conv1 و Layer1-4 در هر یک از نقاط زمانی استخراج شدند. این بازنمایی‌ها برای یک مجموعه ثابت شامل ۱۰۰۰ نمونه از مجموعه آزمون محاسبه شده و با بازنمایی متناظر همان لایه در مدل نهایی مقایسه شدند.

برای محاسبه معیارهای NC1 تا NC4، ویژگی‌های خروجی لایه تجمع میانگین برای تمام ۵۰۰۰۰ نمونه مجموعه آموزش استخراج شدند. خروجی این لایه برای هر نمونه به یک بردار ۵۱۲ بعدی تبدیل شد و به همراه برچسب کلاس نمونه‌ها برای محاسبه معیارهای فروپاشی عصبی مورد استفاده قرار گرفت.

بنابراین، در این پژوهش دو نوع تحلیل بر روی بازنمایی‌های شبکه انجام شد. تحلیل نخست، تغییرات بازنمایی را در لایه‌های مختلف شبکه با استفاده از CKA بررسی می‌کند، در حالی که تحلیل دوم، ساختار هندسی فضای ویژگی ۵۱۲ بعدی پیش از لایه طبقه‌بندی را با استفاده از معیارهای NC ارزیابی می‌کند.

۱.۵.۳ معیار شباهت نمایش‌ها

به منظور بررسی میزان شباهت نمایش‌های حاصل از مراحل مختلف آموزش، از معیار CKA خطی استفاده شد. در این پژوهش، نمایش‌های استخراج‌شده از هر نقطه ذخیره‌شده از فرآیند آموزش با نمایش متناظر مدل نهایی (دوره ۳۵۰) مقایسه شدند تا روند تثبیت فضای ویژگی در طول آموزش مورد بررسی قرار گیرد.

فرض شود دو ماتریس ویژگی

$$X \in \mathbb{R}^{n \times d}, \qquad Y \in \mathbb{R}^{n \times d},$$

به ترتیب نمایش‌های استخراج‌شده از دو مرحله مختلف آموزش باشند، که در آن n تعداد نمونه‌ها و d بعد فضای ویژگی است.

ابتدا هر دو ماتریس ویژگی حول میانگین ستون‌های خود مرکزدهی می‌شوند:

$$\tilde{X} = X - \mathbf{1}\mu_X^T, \qquad \tilde{Y} = Y - \mathbf{1}\mu_Y^T,$$

که در آن μ_X و μ_Y به ترتیب میانگین ستون‌های X و Y هستند.

سپس مقدار CKA خطی مطابق رابطه زیر محاسبه می‌شود:

$$\mathrm{CKA}(X, Y) = \frac{\|\tilde{X}^T\tilde{Y}\|_F^2}{\|\tilde{X}^T\tilde{X}\|_F \, \|\tilde{Y}^T\tilde{Y}\|_F},$$

که در آن $\|\cdot\|_F$ نرم فروبنیوس را نشان می‌دهد.

در این پژوهش، برای هر نقطه ذخیره‌شده از فرآیند آموزش، مقدار CKA بین نمایش‌های همان نقطه و نمایش‌های مدل نهایی محاسبه شد. افزایش تدریجی مقدار CKA نشان‌دهنده نزدیک شدن نمایش‌های داخلی شبکه به نمایش نهایی و در نتیجه پایدار شدن فضای ویژگی در طول آموزش است. از آنجا که مقدار CKA در بازه صفر تا یک قرار دارد، مقادیر نزدیک به یک بیانگر شباهت بسیار زیاد میان دو فضای ویژگی هستند.

۲.۵.۳ معیار NC1 : فروپاشی درون کلاسی

اولین مؤلفه فروپاشی عصبی میزان کاهش پراکندگی درون‌کلاسی نسبت به فاصله مراکز کلاس‌ها را اندازه‌گیری می‌کند.

ابتدا میانگین هر کلاس مطابق رابطه زیر محاسبه می‌شود:

$$\mu_c = \frac{1}{N_c} \sum_{i:y_i=c} h_i,$$

که در آن h_i بردار ویژگی نمونه i و N_c تعداد نمونه‌های کلاس c است.

همچنین میانگین کل داده‌ها برابر است با

$$\mu_G = \frac{1}{N}\sum_{i=1}^{N} h_i.$$

سپس میانگین واریانس درون‌کلاسی به صورت

$$\sigma_W^2 = \frac{1}{N}\sum_{c}\sum_{i:y_i=c} \|h_i - \mu_c\|^2,$$

و میانگین پراکندگی بین کلاس‌ها به صورت

$$\sigma_B^2 = \frac{1}{C}\sum_{c} \|\mu_c - \mu_G\|^2,$$

محاسبه می‌شود.
در نهایت، معیار NC1 مطابق رابطه زیر تعریف می‌شود:

$$\mathrm{NC1} = \frac{\sigma_W^2}{\sigma_B^2}.$$

هرچه مقدار این نسبت کوچک‌تر باشد، نمونه‌های هر کلاس حول مرکز کلاس خود متمرکزتر شده‌اند که نشان‌دهنده ظهور مؤلفه اول فروپاشی عصبی است.

۳.۵.۳ معیار NC2 : ساختار سادک چارچوب تنگ هم‌زاویه

دومین مؤلفه فروپاشی عصبی میزان نزدیک شدن مراکز کلاس‌ها به ساختار سادک منتظم چارچوب تنگ هم‌زاویه را اندازه‌گیری می‌کند.
ابتدا میانگین‌های کلاس حول میانگین کل مرکزدهی می‌شوند:

$$\tilde{\mu}_c = \mu_c - \mu_G.$$

سپس طول هر بردار مرکز کلاس محاسبه شده و میانگین آن برابر است با

$$\bar{r} = \frac{1}{C} \sum_{c} \|\tilde{\mu}_c\|.$$

برای ارزیابی برابر بودن اندازه مراکز کلاس، خطای نرمال‌سازی به صورت

$$E_{\text{norm}} = \sqrt{\frac{1}{C} \sum_{c} \left(\frac{\|\tilde{\mu}_c\| - \bar{r}}{\bar{r}} \right)^2},$$

محاسبه می‌شود.

سپس بردارهای مرکز کلاس نرمال‌سازی می‌شوند:

$$\hat{\mu}_c = \frac{\tilde{\mu}_c}{\|\tilde{\mu}_c\|},$$

و ماتریس شباهت زاویه‌ای تشکیل می‌شود:

$$G = \hat{M}\hat{M}^T.$$

در حالت ایده‌آل چارچوب تنگ هم‌زاویه یا ETF داریم

$$G_{ETF} = I - \frac{1}{C-1}(\mathbf{1}\mathbf{1}^T - I).$$

بنابراین خطای زاویه‌ای برابر است با

$$E_{\text{angle}} = \|G - G_{ETF}\|_F.$$

در این پژوهش، معیار نهایی NC2 مطابق رابطه زیر تعریف شده است:

$$\text{NC2} = \sqrt{E_{\text{angle}}^2 + E_{\text{norm}}^2}.$$

این تعریف علاوه بر بررسی هم‌زاویه بودن مراکز کلاس، یکنواخت بودن اندازه آن‌ها را نیز در نظر می‌گیرد و بنابراین تصویر کامل‌تری از نزدیک شدن ساختار ویژگی‌ها به سادک منتظم ارائه می‌دهد.

۴.۵.۳ معیار NC3 : خوددوگانگی

سومین مؤلفه فروپاشی عصبی میزان هم‌راستایی وزن‌های لایه طبقه‌بندی با مراکز کلاس‌ها را اندازه‌گیری می‌کند.

ابتدا میانگین هر کلاس حول میانگین کل مرکزدهی می‌شود:

$$\tilde{M} = M - \mu_G.$$

فرض شود W ماتریس وزن‌های لایه نهایی طبقه‌بندی‌کننده باشد. هر دو ماتریس با استفاده از نرم فروبنیوس نرمال‌سازی می‌شوند:

$$\hat{W} = \frac{W}{\|W\|_F}, \qquad \hat{M} = \frac{\tilde{M}}{\|\tilde{M}\|_F}.$$

در نهایت، معیار NC3 به صورت فاصله فروبنیوس بین این دو ماتریس تعریف می‌شود:

$$\mathrm{NC3} = \|\hat{W} - \hat{M}\|_F.$$

هرچه مقدار این فاصله کوچک‌تر باشد، هم‌راستایی بیشتری میان وزن‌های طبقه‌بندی‌کننده و مراکز کلاس‌ها برقرار شده است.

۵.۵.۳ معیار NC4 : معادل شدن رفتار طبقه‌بند با نزدیک‌ترین مرکز کلاس

چهارمین مؤلفه فروپاشی عصبی بیان می‌کند که تصمیم طبقه‌بندی‌کننده نهایی به تدریج با تصمیم طبقه‌بند نزدیک‌ترین مرکز کلاس یکسان می‌شود.

ابتدا برای هر نمونه دو برچسب مستقل محاسبه می‌شود:

- برچسب حاصل از لایه طبقه‌بندی شبکه،
- برچسب حاصل از نزدیک‌ترین مرکز کلاس در فضای ویژگی.

در این پژوهش، مراکز کلاس با استفاده از ویژگی‌های استخراج‌شده از مجموعه آموزش محاسبه شده و سپس برای ویژگی‌های مجموعه آزمون نزدیک‌ترین مرکز کلاس تعیین گردید. معیار NC4 به صورت نرخ عدم توافق میان این دو پیش‌بینی تعریف می‌شود:

$$\mathrm{NC4} = \frac{1}{N} \sum_{i=1}^{N} \mathbf{1} \left(\hat{y}_i^{FC} \neq \hat{y}_i^{NCC} \right),$$

که در آن $\mathbf{1}(\cdot)$ تابع شاخص است.

در صورت وقوع کامل فروپاشی عصبی انتظار می‌رود مقدار NC4 به صفر میل کند؛ یعنی طبقه‌بند خطی و طبقه‌بند نزدیک‌ترین مرکز کلاس برای تمامی نمونه‌ها تصمیم یکسانی اتخاذ کنند.

۶.۳ طراحی آزمایش و معیار تعیین نقطه پایداری

هدف اصلی این پژوهش، مقایسه زمان تثبیت بازنمایی‌های داخلی شبکه با زمان شکل‌گیری ویژگی‌های هندسی مرتبط با فروپاشی عصبی است. برای این منظور، روند تغییرات معیار CKA برای لایه‌های مختلف شبکه و همچنین چهار معیار اصلی NC1 تا NC4 در طول فرآیند آموزش مورد بررسی قرار گرفت.

برای هر معیار، ابتدا مقدار نهایی آن در دوره ۳۵۰ تعیین شد. سپس بر اساس ماهیت معیار، یک شرط برای تعیین نقطه پایداری در نظر گرفته شد. برای معیارهایی که مقدار آن‌ها در حالت

فروپاشی عصبی کاهش می‌یابد، نقطه پایداری به عنوان نخستین دوره‌ای تعریف شد که مقدار معیار به محدوده تعیین‌شده نسبت به مقدار نهایی رسیده و پس از آن تا پایان آموزش در همان محدوده باقی بماند.

در این پژوهش، برای معیارهای کاهشی، آستانه پایداری برابر با ۱/۲ برابر مقدار نهایی معیار در نظر گرفته شد. بنابراین، اگر مقدار معیار در دوره e شرط

$$M(e) \leq ۱/۲ M_{\text{final}}$$

را برقرار کند، این دوره تنها در صورتی به عنوان نقطه پایداری پذیرفته می‌شود که شرط مذکور برای تمام نقاط زمانی بعدی نیز برقرار باقی بماند.

این شرط که در این پژوهش با عنوان پایداری سخت[۱۶] شناخته می‌شود، از انتخاب نقاطی جلوگیری می‌کند که تنها به صورت موقت به مقدار نهایی نزدیک شده‌اند.

برای معیار CKA، از آنجا که مقدار معیار با نزدیک شدن بازنمایی به حالت نهایی افزایش می‌یابد، دو آستانه مطلق ۰/۹۵ و ۰/۹۹ در نظر گرفته شد. در این حالت، نقطه تثبیت برابر با نخستین دوره‌ای است که مقدار CKA از آستانه مورد نظر عبور کرده و تا پایان آموزش همچنان بالاتر از آن باقی بماند.

در نهایت، زمان‌های تثبیت به‌دست‌آمده برای CKA و معیارهای NC با یکدیگر مقایسه شدند. این مقایسه برای بررسی این موضوع انجام شد که آیا بازنمایی‌های داخلی شبکه پیش از شکل‌گیری ساختار هندسی فروپاشی عصبی به وضعیت پایدار نزدیک می‌شوند، یا این دو فرآیند در زمان‌های مشابه رخ می‌دهند و یا شکل‌گیری ساختار هندسی پس از تثبیت بازنمایی‌ها ادامه پیدا می‌کند.

[16] Strict Stabilization

فصل ۴

آزمایش‌ها و نتایج

۱.۴ تکامل لایه‌ای نمایش‌ها در طول آموزش

به منظور بررسی روند تکامل بازنمایی‌های داخلی شبکه در طول فرآیند آموزش، معیار Centered Kernel Alignment (CKA) برای پنج بخش اصلی معماری ResNet-18 شامل Conv1، Layer1، Layer2، Layer3 و Layer4 محاسبه شد. در این تحلیل، بازنمایی هر لایه در نقاط زمانی مختلف با بازنمایی همان لایه در مدل نهایی، یعنی دوره ۳۵۰، مقایسه شد. بنابراین، مقدار CKA نشان‌دهنده میزان شباهت بازنمایی یک لایه در هر نقطه از آموزش با بازنمایی نهایی همان لایه است.

برای تحلیل زمان نزدیک شدن بازنمایی‌ها به حالت نهایی، دو آستانه ۰/۹۵ و ۰/۹۹ در نظر گرفته شد. در هر آستانه، دو زمان متفاوت مورد بررسی قرار گرفت: نخستین عبور از آستانه و تثبیت سخت. نخستین عبور، اولین دوره‌ای است که مقدار CKA به آستانه مورد نظر می‌رسد یا از آن فراتر می‌رود. در مقابل، تثبیت سخت نخستین دوره‌ای است که از آن به بعد مقدار CKA در تمام نقاط زمانی باقی‌مانده بالاتر از آستانه قرار می‌گیرد. در نتیجه، نخستین عبور زمان دستیابی اولیه به سطح مشخصی از شباهت را نشان می‌دهد، در حالی که تثبیت سخت بیانگر حفظ پایدار این سطح از شباهت تا پایان آموزش است.

جدول ۱.۴: دوره نخستین عبور و تثبیت سخت لایه‌های مختلف بر اساس معیار CKA

لایه	تثبیت سخت (۰/۹۵)	نخستین عبور (۰/۹۵)	تثبیت سخت (۰/۹۹)	نخستین عبور (۰/۹۹)
Conv1	۷۰	۷	۲۶۶	۱۵
Layer1	۲۷۴	۳۰	۳۰۰	۲۹۶
Layer2	۲۷۰	۲۴۴	۳۰۲	۳۰۲
Layer3	۲۹۸	۲۹۸	۳۱۴	۳۱۴
Layer4	۲۹۰	۲۹۰	۳۰۶	۳۰۶

نتایج حاصل از این تحلیل در جدول زیر ارائه شده است.

بر اساس نتایج جدول، تفاوت قابل توجهی میان زمان نخستین عبور و زمان تثبیت سخت در برخی لایه‌ها مشاهده می‌شود. این تفاوت به‌ویژه در لایه Conv1 مشهود است. در این لایه، مقدار CKA در دوره ۷ به آستانه ۰/۹۵ می‌رسد، اما تثبیت سخت آن در دوره ۷۰ رخ می‌دهد. همچنین، برای آستانه ۰/۹۹ ، نخستین عبور در دوره ۱۵ اتفاق می‌افتد، در حالی که تثبیت سخت در دوره ۲۶۶ حاصل می‌شود. این اختلاف نشان می‌دهد که رسیدن اولیه بازنمایی این لایه به شباهت بالا با بازنمایی نهایی، لزوماً به معنای حفظ آن سطح از شباهت در ادامه آموزش نیست.

در لایه‌های عمیق‌تر، روند متفاوتی مشاهده می‌شود. در Layer2، نخستین عبور از آستانه ۰/۹۵ در دوره ۲۴۴ اتفاق افتاده و تثبیت سخت در دوره ۲۷۰ حاصل شده است. در آستانه ۰/۹۹ نیز هر دو زمان برابر با دوره ۳۰۲ هستند. این موضوع نشان می‌دهد که در این لایه، فاصله زمانی میان دستیابی اولیه به آستانه و حفظ پایدار آن، به‌ویژه در آستانه بالاتر، بسیار کمتر از لایه ابتدایی است.

در Layer3، نخستین عبور و تثبیت سخت برای هر دو آستانه یکسان هستند. این دو مقدار برای آستانه ۰/۹۵ در دوره ۲۹۸ و برای آستانه ۰/۹۹ در دوره ۳۱۴ به دست آمده‌اند. بنابراین، پس از رسیدن مقدار CKA این لایه به هر یک از آستانه‌های مورد نظر، در نقاط زمانی بعدی نیز شرط مربوطه حفظ شده است. در Layer4 نیز همین الگو مشاهده می‌شود؛ به طوری که نخستین عبور و تثبیت سخت در آستانه ۰/۹۵ هر دو در دوره ۲۹۰ و در آستانه ۰/۹۹ هر دو در دوره ۳۰۶ رخ داده‌اند.

در Layer1، نخستین عبور از آستانه ۰/۹۵ در دوره ۳۰ اتفاق افتاده است، اما تثبیت سخت تا دوره ۲۷۴ حاصل نشده است. این اختلاف نشان می‌دهد که بازنمایی این لایه در بخش قابل

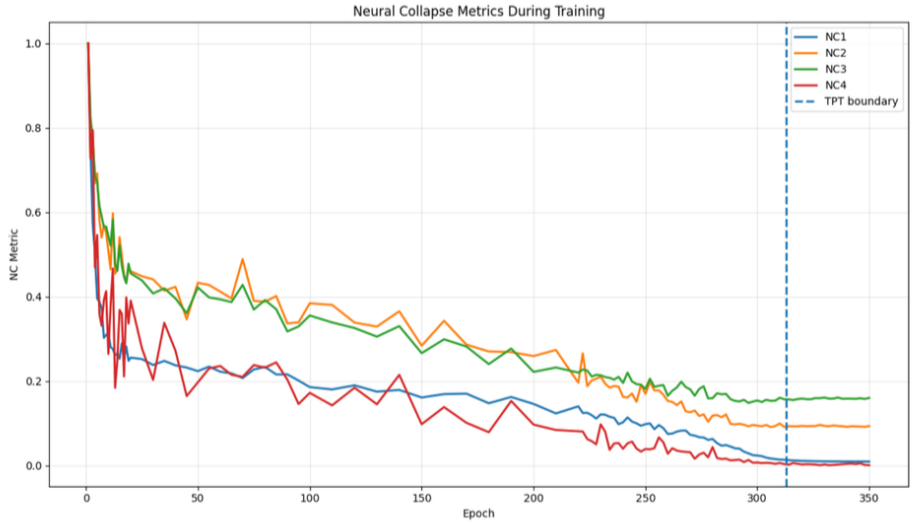
توجهی از فرآیند آموزش، با وجود دستیابی اولیه به سطح شباهت ۰/۹۵، همچنان تغییراتی داشته است که باعث خروج موقت مقدار CKA از محدوده آستانه شده‌اند. برای آستانه ۰/۹۹ نیز نخستین عبور در دوره ۲۹۶ و تثبیت سخت در دوره ۳۰۰ اتفاق افتاده است که نشان‌دهنده فاصله زمانی بسیار کمتر میان دستیابی اولیه و حفظ پایدار شباهت در این سطح است.

در مجموع، نتایج نشان می‌دهند که زمان دستیابی اولیه به شباهت بالا با بازنمایی نهایی و زمان حفظ پایدار آن، در همه لایه‌ها یکسان نیست. به‌ویژه، در لایه‌های Conv1 و Layer1 فاصله قابل توجهی میان نخستین عبور و تثبیت سخت مشاهده می‌شود، در حالی که در لایه‌های عمیق‌تر، این دو زمان به یکدیگر نزدیک‌تر هستند یا با هم برابرند. همچنین، افزایش آستانه از ۰/۹۵ به ۰/۹۹ در تمام لایه‌ها باعث دیرتر شدن زمان تثبیت سخت شده است.

نکته مهم آن است که تثبیت سخت CKA به معنای توقف کامل یادگیری یا ثابت ماندن پارامترهای شبکه نیست؛ بلکه نشان می‌دهد بازنمایی یک لایه از آن نقطه به بعد، بر اساس آستانه انتخاب‌شده، شباهت بالایی با بازنمایی نهایی خود حفظ می‌کند. از این رو، در ادامه پژوهش، زمان‌های تثبیت سخت به عنوان معیار اصلی برای مقایسه پایداری بازنمایی‌های داخلی با روند شکل‌گیری ویژگی‌های هندسی مرتبط با فروپاشی عصبی مورد استفاده قرار می‌گیرند.

۲.۴ مسیر شکل‌گیری و تثبیت فروپاشی عصبی

برای بررسی مسیر شکل‌گیری پدیده فروپاشی عصبی در طول فرآیند آموزش، چهار مؤلفه اصلی آن شامل NC1، NC2، NC3 و NC4 در تمام دوره‌های آموزش محاسبه و دنبال شدند. در این آزمایش، برای NC3 از تعریف رسمی مبتنی بر مقایسه وزن‌های لایه طبقه‌بندی‌کننده با میانگین‌های کلاسی استفاده شد. همچنین، برای NC2 معیار ترکیبی مورد استفاده قرار گرفت و مؤلفه‌های زاویه‌ای و نُرم در تحلیل‌های تکمیلی مورد بررسی قرار گرفتند.



شکل ۱.۴: مسیر نسبی همگرایی مؤلفه‌های فروپاشی عصبی در طول آموزش. مقادیر به‌صورت میزان پیشرفت نسبت به وضعیت نهایی هر معیار نمایش داده شده‌اند. خط عمودی مشخص‌کننده مرز ورود به فاز پایانی آموزش در دوره ۳۱۳ است.

از آنجا که مقیاس و جهت چهار معیار NC یکسان نیست، برای مقایسه مسیر همگرایی آن‌ها، مقادیر به‌صورت نسبی نسبت به وضعیت نهایی هر معیار نمایش داده شدند. در این نمایش، مقدار بالاتر نشان‌دهنده پیشرفت بیشتر به سمت وضعیت نهایی فروپاشی عصبی است. شکل ۱.۴ مسیر نسبی چهار معیار NC را در طول ۳۵۰ دوره آموزش نشان می‌دهد.

همان‌طور که در شکل ۱.۴ مشاهده می‌شود، چهار مؤلفه فروپاشی عصبی با سرعت یکسانی به وضعیت نهایی خود نزدیک نمی‌شوند. در مراحل ابتدایی آموزش، هر چهار معیار تغییرات قابل توجهی دارند و بخش قابل توجهی از فاصله خود با وضعیت نهایی را کاهش می‌دهند. با ادامه آموزش، روند تغییرات تدریجاً منظم‌تر شده و در نیمه دوم آموزش، معیارها به مقادیر نهایی خود نزدیک می‌شوند.

برای تعیین زمان تثبیت هر معیار، همان معیار تثبیت سخت که در فصل روش‌شناسی تعریف شد مورد استفاده قرار گرفت. بر اساس این معیار، زمان تثبیت NC3 در دوره ۲۶۸، NC4 در دوره ۲۸۲، مؤلفه زاویه‌ای NC2 در دوره ۲۸۴ و معیار ترکیبی NC2 در دوره ۲۸۸ به دست آمد. در

مقابل، NC1 در دوره ۳۲۰ به شرط تثبیت رسید.

جدول ۲.۴: زمان تثبیت مؤلفه‌های فروپاشی عصبی و مقایسه آن با مرز فاز نهایی آموزش.

معیار	دوره تثبیت	نسبت به فاز پایانی آموزش
NC3	۲۶۸	پیش از
NC4	۲۸۲	پیش از
NC2 Angular	۲۸۴	پیش از
NC2	۲۸۸	پیش از
NC1	۳۲۰	پس از
TPT	۳۱۳	—

در این آزمایش، مرز فاز پایانی آموزش در دوره ۳۱۳ تعیین شد. این دوره نخستین دوره‌ای است که در آن دقت آموزش به ۱۰۰ رسیده و در نتیجه خطای طبقه‌بندی روی مجموعه آموزش به صفر رسیده است. بنابراین، دوره ۳۱۳ به‌عنوان نقطه شروع TPT در تحلیل حاضر در نظر گرفته شد.

مقایسه زمان‌های تثبیت با این مرز نشان می‌دهد که بخش عمده مؤلفه‌های فروپاشی عصبی پیش از ورود به TPT به وضعیت تثبیت خود نزدیک شده‌اند. به‌طور مشخص، NC3 با دوره تثبیت ۲۶۸ زودتر از سایر معیارهای NC تثبیت می‌شود و پس از آن NC4، NC2 Angular و NC2 به‌ترتیب در دوره‌های ۲۸۲، ۲۸۴ و ۲۸۸ تثبیت می‌شوند. هر چهار این زمان‌ها پیش از دوره ۳۱۳ قرار دارند.

در مقابل، NC1 رفتار متفاوتی نشان می‌دهد. زمان تثبیت سخت این معیار برابر با دوره ۳۲۰ است که هفت دوره پس از شروع TPT قرار دارد. بنابراین، در آزمایش حاضر، رسیدن شبکه به صفر شدن خطای طبقه‌بندی با تثبیت کامل همه مؤلفه‌های فروپاشی عصبی همزمان نیست. به بیان دیگر، اگرچه بخش عمده ساختار فروپاشی عصبی پیش از ورود به TPT شکل گرفته است، NC1 همچنان پس از ورود به این فاز به سمت وضعیت نهایی خود حرکت می‌کند.

این نتیجه نشان می‌دهد که صفر شدن خطای آموزش را نمی‌توان به‌تنهایی معادل پایان کامل تغییرات نمایش داخلی شبکه در نظر گرفت. در حالی که شبکه در دوره ۳۱۳ به عملکرد کامل روی داده‌های آموزش دست یافته است، ساختار درون‌کلاسی نمایش‌ها که توسط NC1 اندازه‌گیری

می‌شود، هنوز تا رسیدن به معیار تثبیت تعریف‌شده در این مطالعه به تغییر خود ادامه می‌دهد. از این منظر، TPT را می‌توان به‌عنوان مرزی میان پایان یادگیری طبقه‌بندی روی داده‌های آموزش و ادامه سازمان‌دهی هندسی نمایش‌های داخلی در نظر گرفت.

در مجموع، ترتیب زمانی به‌دست‌آمده نشان می‌دهد که مؤلفه‌های مختلف فروپاشی عصبی به‌صورت همزمان ظاهر یا تثبیت نمی‌شوند. در آزمایش حاضر، NC3 زودتر از سایر مؤلفه‌ها تثبیت شده و پس از آن NC4 و مؤلفه‌های NC2 قرار می‌گیرند، در حالی که NC1 دیرتر و پس از ورود به TPT به معیار تثبیت سخت می‌رسد. این تفاوت زمانی، مبنای مناسبی برای بررسی رابطه میان ظهور فروپاشی عصبی و تثبیت نمایش‌ها در ادامه‌ی فصل فراهم می‌کند.

۳.۴ خطای آموزش و آغاز مرحله پایانی آموزش

در این آزمایش، مرحله پایانی آموزش به‌صورت عملیاتی به‌عنوان مرحله‌ای تعریف شد که از نخستین دوره‌ای آغاز می‌شود که خطای آموزش به صفر می‌رسد. بر اساس روند آموزش، نخستین دستیابی به دقت آموزش ۱۰۰ در دوره ۳۱۳ مشاهده شد. بنابراین، دوره ۳۱۳ به‌عنوان آغاز TPT در تحلیل‌های بعدی در نظر گرفته شد.

با این حال، رسیدن به خطای آموزش صفر به این معنا نیست که فرایند بهینه‌سازی متوقف شده یا پارامترهای شبکه پس از آن دوره کاملاً ثابت می‌شوند. همان‌طور که در نتایج مشاهده می‌شود، پس از دوره ۳۱۳ دقت آموزش در برخی دوره‌ها اندکی از مقدار ۱۰۰ کاهش می‌یابد، در حالی که همچنان بسیار نزدیک به حالت طبقه‌بندی کامل باقی می‌ماند. برای مثال، دقت آموزش در دوره‌های ۳۱۴، ۳۱۵ و ۳۲۱ به‌ترتیب برابر با ۹۹٫۹۹۸، ۹۹٫۹۸۸ و ۹۹٫۹۹۴ بوده است. این نوسانات کوچک تا پایان آموزش در دوره ۳۵۰ نیز ادامه دارند.

از آنجا که مجموعه آموزش شامل ۵۰,۰۰۰ نمونه است، این تغییرات معادل تعداد بسیار کمی از نمونه‌های اشتباه طبقه‌بندی‌شده هستند. برای مثال، دقت ۹۹٫۹۹۸ تقریباً معادل یک نمونه خطادار، دقت ۹۹٫۹۹۶ معادل دو نمونه خطادار و دقت ۹۹٫۹۹۴ معادل سه نمونه خطادار است. بنابراین، نوسانات مشاهده‌شده پس از دوره ۳۱۳ نشان‌دهنده افت قابل توجه عملکرد آموزش نیستند، بلکه بیانگر تغییرات بسیار کوچک در اطراف یک وضعیت تقریباً بدون خطا هستند.

ادامه تغییرات پس از رسیدن به خطای صفر به این دلیل است که فرایند بهینه‌سازی تا پایان تعداد دوره‌های تعیین‌شده ادامه پیدا می‌کند. در آزمایش حاضر، الگوریتم گرادیان کاهشی تصادفی همراه با مومنتوم همچنان فعال است و زمان‌بندی نرخ یادگیری کسینوسی نیز در دوره‌های بعدی اعمال می‌شود. در نتیجه، حتی پس از آنکه تمام نمونه‌های آموزشی به‌درستی طبقه‌بندی شده‌اند، به‌روزرسانی‌های کوچک پارامترها می‌توانند همچنان ادامه داشته باشند. این تغییرات ممکن است باعث شوند تعداد بسیار کمی از نمونه‌ها در دوره‌های مختلف از یک مرز تصمیم عبور کنند و در نتیجه دقت آموزش بین مقادیر بسیار نزدیک به ۱۰۰ نوسان داشته باشد.

روند تابع زیان آموزش نیز نشان می‌دهد که بهینه‌سازی پس از آغاز TPT همچنان ادامه دارد.

اگرچه دقت آموزش در این مرحله عملاً اشباع شده است، مقدار زیان متقاطع در دوره‌های ۳۰۹ تا ۳۵۰ همچنان در مقادیر کوچکی در حدود ۰/۰۰۱۶ تا ۰/۰۰۲۱ نوسان می‌کند. این تفاوت از آنجا ناشی می‌شود که دقت طبقه‌بندی تنها به درست یا نادرست بودن کلاس پیش‌بینی‌شده وابسته است، در حالی که تابع زیان آنتروپی متقاطع علاوه بر صحت پیش‌بینی، میزان اطمینان مدل نسبت به کلاس صحیح را نیز در نظر می‌گیرد. بنابراین، شبکه می‌تواند حتی در شرایطی که دقت آموزش برابر با ۱۰۰ باقی می‌ماند، به تغییر بازنمایی‌ها و میزان اطمینان خود ادامه دهد.

از این رو، دوره ۳۱۳ در این پژوهش باید به‌عنوان *آغاز* TPT بر اساس تعریف عملیاتی مورد استفاده تفسیر شود، نه به‌عنوان نقطه‌ای که در آن تمام پارامترها یا بازنمایی‌های شبکه به‌طور کامل ثابت می‌شوند. دوره‌های پس از ۳۱۳ را می‌توان به‌عنوان ادامه بهینه‌سازی در ناحیه‌ای در نظر گرفت که در آن خطای آموزش عملاً صفر و عملکرد طبقه‌بندی اشباع شده است. این تمایز در مقایسه میان مرز TPT و زمان تثبیت معیارهای فروپاشی عصبی و CKA اهمیت دارد، زیرا نشان می‌دهد که آغاز TPT الزاماً با تثبیت کامل تمام ویژگی‌های هندسی و بازنمایی شبکه در یک دوره واحد یکسان نیست.

۴.۴ پویایی مشترک بازنمایی و فروپاشی عصبی

پس از بررسی جداگانه روند تکامل بازنمایی‌های داخلی با استفاده از معیار CKA و روند شکل‌گیری مؤلفه‌های فروپاشی عصبی، در این بخش رابطه زمانی میان این دو پدیده بررسی می‌شود. هدف اصلی این تحلیل، مقایسه زمان نزدیک شدن بازنمایی‌های لایه‌های مختلف شبکه به وضعیت نهایی با زمان تثبیت ویژگی‌های هندسی مرتبط با فروپاشی عصبی است. به این ترتیب، می‌توان بررسی کرد که آیا تثبیت بازنمایی‌های داخلی و شکل‌گیری ساختار هندسی فضای ویژگی در زمان مشابهی رخ می‌دهند یا هر یک از این فرایندها روند زمانی متفاوتی دارند.

برای این منظور، زمان تثبیت معیارهای NC1 تا NC4 با زمان تثبیت سخت معیار CKA در لایه‌های مختلف شبکه مقایسه شد. در تحلیل CKA دو آستانه ۰/۹۵ و ۰/۹۹ در نظر گرفته شدند. برای هر آستانه، نخستین عبور از آستانه و تثبیت سخت به صورت جداگانه محاسبه شدند. نخستین

عبور، اولین دوره‌ای است که مقدار CKA به آستانه مورد نظر می‌رسد یا از آن فراتر می‌رود؛ در حالی که تثبیت سخت، نخستین دوره‌ای است که از آن به بعد مقدار CKA در تمام نقاط زمانی باقی‌مانده بالاتر از آستانه قرار می‌گیرد. از آنجا که هدف این بخش مقایسه زمان پایداری بازنمایی‌ها با مؤلفه‌های فروپاشی عصبی است، در مقایسه اصلی از زمان‌های تثبیت سخت استفاده می‌شود و زمان‌های نخستین عبور صرفاً برای تکمیل تحلیل در نظر گرفته می‌شوند.

نتایج مقایسه زمان تثبیت مؤلفه‌های فروپاشی عصبی و لایه‌های مختلف CKA در جدول ۳.۴ ارائه شده است.

جدول ۳.۴: مقایسه زمان تثبیت سخت مؤلفه‌های فروپاشی عصبی و لایه‌های مختلف بر اساس معیار CKA

معیار	دوره تثبیت سخت
NC3	۲۶۸
NC4	۲۸۲
NC2 Angular	۲۸۴
NC2	۲۸۸
(۰/۹۵) CKA Conv1	۷۰
(۰/۹۵)) CKA Layer1	۲۷۴
(۰/۹۵) CKA Layer2	۲۷۰
(۰/۹۵) CKA Layer3	۲۹۸
(۰/۹۵) CKA Layer4	۲۹۰
(۰/۹۹) CKA Conv1	۲۶۶
(۰/۹۹) CKA Layer1	۳۰۰
(۰/۹۹) CKA Layer2	۳۰۲
(۰/۹۹) CKA Layer3	۳۱۴
(۰/۹۹) CKA Layer4	۳۰۶
NC1	۳۲۰

بر اساس نتایج جدول، زمان تثبیت مؤلفه‌های فروپاشی عصبی و زمان تثبیت بازنمایی‌ها در لایه‌های مختلف یکسان نیست. در آستانه ۰/۹۵، لایه Conv1 زودتر از سایر معیارها به تثبیت سخت می‌رسد و این اتفاق در دوره ۷۰ رخ می‌دهد. با این حال، تثبیت سایر لایه‌ها به زمان‌های دیرتری موکول می‌شود. برای مثال، Layer2 و Layer1 به ترتیب در دوره‌های ۲۷۰ و ۲۷۴ تثبیت می‌شوند، در حالی که تثبیت سخت Layer4 و Layer3 به ترتیب در دوره‌های ۲۹۰ و ۲۹۸ اتفاق

می‌افتد.

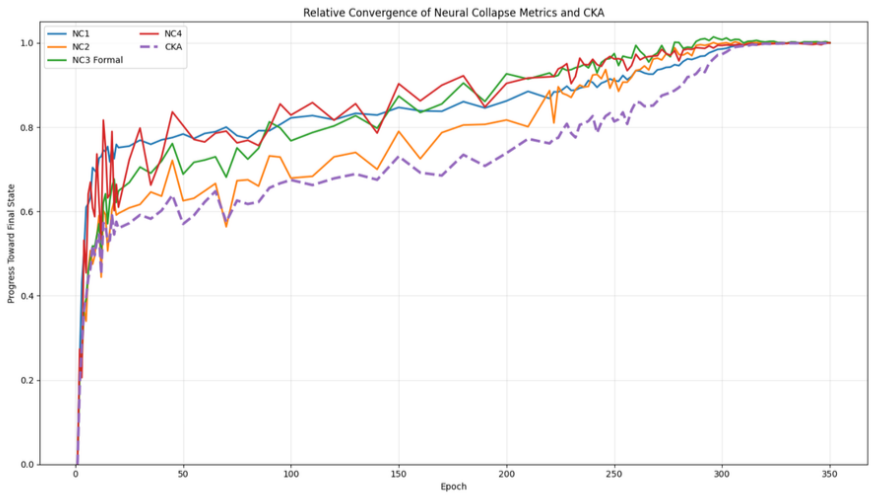
در مقایسه با این نتایج، معیار NC3 در دوره ۲۶۸ تثبیت می‌شود؛ بنابراین، تثبیت آن پیش از تثبیت سخت بیشتر لایه‌ها در آستانه ۰/۹۵ رخ می‌دهد، اما پس از تثبیت Conv1 قرار دارد. همچنین، NC4 و مؤلفه زاویه‌ای NC2 به ترتیب در دوره‌های ۲۸۲ و ۲۸۴ تثبیت می‌شوند. این دو معیار پس از تثبیت سخت Layer1 و Layer2، اما پیش از تثبیت سخت Layer3 و Layer4 قرار می‌گیرند. معیار ترکیبی NC2 نیز در دوره ۲۸۸ تثبیت می‌شود که از نظر زمانی به تثبیت Layer4 در دوره ۲۹۰ بسیار نزدیک است. فاصله دو دوره‌ای میان این دو رویداد نشان‌دهنده نزدیکی زمانی آن‌ها در این آزمایش است، هرچند به دلیل تفاوت ماهیت معیارها نمی‌توان آن‌ها را یک رویداد کاملاً همزمان در نظر گرفت.

با افزایش آستانه CKA از ۰/۹۵ به ۰/۹۹، زمان تثبیت سخت تمام لایه‌ها افزایش می‌یابد. در این حالت، Conv1 در دوره ۲۶۶، Layer1 در دوره ۳۰۰، Layer2 در دوره ۳۰۲، Layer4 در دوره ۳۰۶ و Layer3 در دوره ۳۱۴ به تثبیت سخت می‌رسند. این نتایج نشان می‌دهند که حتی پس از تثبیت بازنمایی‌ها در سطح شباهت ۰/۹۵، نزدیک شدن آن‌ها به سطح بالاتر شباهت با بازنمایی نهایی ادامه پیدا می‌کند.

در این آستانه سخت‌گیرانه‌تر، NC3، NC4 و مؤلفه‌های NC2 همگی پیش از تثبیت سخت لایه‌های Layer1 تا Layer4 قرار می‌گیرند. با این حال، تثبیت Conv1 در دوره ۲۶۶ اندکی پیش از تثبیت NC3 در دوره ۲۶۸ رخ می‌دهد. همچنین، تثبیت NC1 در دوره ۳۲۰ اتفاق می‌افتد که پس از تثبیت سخت تمام لایه‌ها در آستانه ۰/۹۹ قرار دارد. بنابراین، در حالی که بخش عمده مؤلفه‌های هندسی فروپاشی عصبی پیش از رسیدن لایه‌های عمیق به سطح شباهت ۰/۹۹ تثبیت می‌شوند، تثبیت NC1 حتی پس از آن نیز ادامه دارد.

برای تکمیل این تحلیل، تفاوت میان نخستین عبور و تثبیت سخت نیز اهمیت دارد. برای نمونه، در Conv1 نخستین عبور از آستانه ۰/۹۵ در دوره ۷ رخ داده است، اما تثبیت سخت آن تا دوره ۷۰ به تأخیر می‌افتد. در Layer1 نیز نخستین عبور از آستانه ۰/۹۵ در دوره ۳۰ اتفاق می‌افتد، در حالی که تثبیت سخت آن در دوره ۲۷۴ حاصل می‌شود. این اختلاف نشان می‌دهد که رسیدن اولیه یک لایه به سطح مشخصی از شباهت با بازنمایی نهایی، لزوماً به معنای حفظ آن سطح

از شباهت در ادامه آموزش نیست. از این رو، استفاده از نخستین عبور به تنهایی برای تعیین زمان پایداری بازنمایی‌ها کافی نیست.



شکل ۲.۴: مقایسه روند نزدیک شدن مؤلفه‌های فروپاشی عصبی و بازنمایی‌های لایه‌ای شبکه به وضعیت نهایی در طول آموزش.

در مجموع، نتایج این آزمایش از شکل‌گیری تدریجی و چندمرحله‌ای ساختار بازنمایی و ویژگی‌های هندسی فروپاشی عصبی پشتیبانی می‌کنند. ابتدا برخی از مؤلفه‌های فروپاشی عصبی، از جمله NC3، به معیار تثبیت خود می‌رسند. سپس NC4 و مؤلفه‌های NC2 تثبیت می‌شوند و در همین بازه زمانی، بازنمایی لایه‌های مختلف نیز به تدریج به وضعیت نهایی خود نزدیک می‌شوند. با این حال، زمان تثبیت لایه‌ها به آستانه انتخاب‌شده وابسته است؛ به طوری که در آستانه ۰/۹۵، تثبیت برخی لایه‌ها پیش از مؤلفه‌های NC و برخی پس از آن‌ها رخ می‌دهد، در حالی که در آستانه ۰/۹۹، تثبیت سخت بیشتر لایه‌های عمیق پس از تثبیت عمده مؤلفه‌های NC اتفاق می‌افتد.

بر این اساس، پاسخ به پرسش اصلی این بخش مبنی بر اینکه آیا ساختار بازنمایی دقیقاً همزمان با شکل‌گیری ساختار هندسی فروپاشی عصبی تثبیت می‌شود، منفی است. هرچند نزدیکی زمانی میان تثبیت NC2 در دوره ۲۸۸ و تثبیت سخت Layer4 در آستانه ۰/۹۵ در دوره ۲۹۰ مشاهده می‌شود، این نزدیکی را نمی‌توان به تمام لایه‌ها و مؤلفه‌های NC تعمیم داد. افزون بر این، تثبیت

سخت لایه‌های مختلف در آستانه ۰/۹۹ تا دوره ۳۱۴ ادامه دارد، در حالی که NC1 در دوره ۳۲۰ به معیار تثبیت خود می‌رسد. بنابراین، تکامل بازنمایی‌های داخلی و شکل‌گیری ویژگی‌های هندسی فروپاشی عصبی با یکدیگر ارتباط زمانی دارند، اما نمی‌توان آن‌ها را دو اندازه‌گیری هم‌ارز از یک رویداد زمانی واحد دانست.

این تفاوت با ماهیت دو گروه معیار نیز سازگار است. معیارهای NC تغییرات هندسی فضای ویژگی و روابط میان نمونه‌ها و میانگین‌های کلاسی را ارزیابی می‌کنند، در حالی که CKA میزان شباهت بازنمایی یک لایه در طول آموزش را با بازنمایی مرجع همان لایه در مدل نهایی اندازه‌گیری می‌کند. در نتیجه، تثبیت یک مؤلفه هندسی لزوماً به معنای تثبیت تمام بازنمایی‌های داخلی شبکه نیست و برعکس، شباهت زیاد یک لایه با بازنمایی نهایی نیز به تنهایی شکل‌گیری کامل تمام مؤلفه‌های فروپاشی عصبی را تضمین نمی‌کند.

این یافته‌ها را می‌توان در ارتباط با مرحله پایانی آموزش یا TPT نیز بررسی کرد. در آزمایش حاضر، شروع TPT در دوره ۳۱۳ در نظر گرفته شده است. این زمان پس از تثبیت سخت تمام لایه‌ها در آستانه ۰/۹۵ و پس از تثبیت سخت چهار لایه از پنج لایه در آستانه ۰/۹۹ قرار دارد؛ با این حال، تثبیت سخت Layer3 در آستانه ۰/۹۹ در دوره ۳۱۴ و تثبیت NC1 در دوره ۳۲۰ رخ می‌دهد. بنابراین، ورود به TPT را نمی‌توان به معنای پایان کامل تغییرات بازنمایی یا تثبیت تمام مؤلفه‌های هندسی شبکه دانست. در عوض، نتایج نشان می‌دهند که حتی پس از ورود به این مرحله، برخی از جنبه‌های ساختار داخلی شبکه همچنان به سمت وضعیت نهایی خود تکامل می‌یابند.

فصل ۵

نتیجه گیری و کار آینده

۱.۵ پویایی آموزش

یافته‌های این پژوهش نشان می‌دهند که پویایی آموزش یک شبکه‌ی عمیق را نمی‌توان به یک مسیر یکنواخت از «یادگیری» تا «توقف» تقلیل داد. آنچه در طول آموزش تغییر می‌کند، تنها خروجی نهایی شبکه نیست؛ بلکه سازمان‌دهی درونی بازنمایی‌ها نیز به تدریج دستخوش تغییر می‌شود. از این دیدگاه، آموزش را می‌توان فرایندی دانست که در آن چند جنبه‌ی متفاوت از شبکه، از جمله عملکرد پیش‌بینی، بازنمایی اطلاعات و هندسه‌ی فضای ویژگی، با سرعت‌ها و الگوهای زمانی متفاوت تحول پیدا می‌کنند.

یکی از پیام‌های اصلی این پژوهش، ضرورت تفکیک میان *موفقیت در وظیفه* و *تکمیل فرایند یادگیری* است. هنگامی که شبکه تمام نمونه‌های آموزشی را به درستی طبقه‌بندی می‌کند، تنها می‌توان نتیجه گرفت که معیار گسسته‌ی مورد استفاده برای ارزیابی طبقه‌بندی به سطح مطلوبی رسیده است. این وضعیت به خودی خود اطلاعاتی درباره‌ی ثابت‌شدن پارامترها یا بازنمایی‌های داخلی ارائه نمی‌دهد. ممکن است دو مدل عملکرد یکسانی روی داده‌های آموزشی داشته باشند، اما ساختارهای درونی متفاوتی را برای رسیدن به این عملکرد ایجاد کرده باشند. بنابراین، دقت طبقه‌بندی برای توصیف کامل وضعیت شبکه در طول آموزش کافی نیست.

از سوی دیگر، تغییرات بازنمایی نیز لزوماً به صورت یکنواخت در تمام لایه‌ها رخ نمی‌دهند. ساختار یک شبکه‌ی عمیق امکان می‌دهد که بخش‌های مختلف آن نقش‌های متفاوتی در فرایند یادگیری ایفا کنند. لایه‌های نزدیک‌تر به ورودی می‌توانند نسبتاً زود به ساختاری پایدار برسند، در حالی که لایه‌های بالاتر همچنان در حال تنظیم روابط میان ویژگی‌های آموخته‌شده و نیازهای مسئله باشند. در نتیجه، مفهوم «زمان تثبیت شبکه» تا حدی وابسته به این است که تثبیت را برای کدام بخش از شبکه و با چه معیاری تعریف کنیم. این مشاهده، استفاده از یک زمان واحد برای توصیف کل فرایند آموزش را با احتیاط بیشتری مواجه می‌کند.

این مسئله را می‌توان به صورت وجود چند *مقیاس زمانی* در آموزش تفسیر کرد. یک مقیاس مربوط به دستیابی به عملکرد مطلوب در وظیفه است؛ مقیاس دیگر به تغییرات بازنمایی‌ها مربوط می‌شود؛ و مقیاس دیگری را می‌توان برای تحول هندسی فضای ویژگی در نظر گرفت. این مقیاس‌ها به یکدیگر وابسته‌اند، اما الزاماً همزمان نیستند. از این رو، یک رویداد آموزشی مانند رسیدن به دقت کامل را بهتر است به عنوان یکی از نقاط عطف فرایند آموزش در نظر گرفت، نه به عنوان مرزی که تمام تغییرات معنادار شبکه در آن پایان می‌یابد.

مقایسه‌ی CKA و معیارهای فروپاشی عصبی نیز اهمیت این تفکیک را روشن می‌کند. این دو دسته معیار را نباید صرفاً به عنوان دو روش متفاوت برای اندازه‌گیری یک کمیت واحد در نظر گرفت. CKA تغییرات ساختاری بازنمایی را در طول زمان آشکار می‌کند، در حالی که معیارهای NC ویژگی‌های خاصی از سازمان‌یافتگی هندسی فضای ویژگی را بررسی می‌کنند. در نتیجه، ترکیب این معیارها امکان مشاهده‌ی ابعاد متفاوتی از یک فرایند پیچیده را فراهم می‌کند. نزدیکی زمانی برخی از تغییرات در این دو نوع اندازه‌گیری می‌تواند وجود ارتباط میان آن‌ها را نشان دهد، اما به معنای هم‌ارزی آن‌ها نیست.

از این منظر، یکی از نتایج مهم پژوهش حاضر به نحوه‌ی تفسیر مفهوم «فروپاشی عصبی» مربوط می‌شود. فروپاشی عصبی را نباید صرفاً به عنوان یک وضعیت نهایی که شبکه ناگهان به آن وارد می‌شود در نظر گرفت. شواهد حاصل از تحلیل زمانی نشان می‌دهند که ویژگی‌های مرتبط با هندسه‌ی فروپاشی می‌توانند به تدریج ظاهر و تثبیت شوند. برخی جنبه‌های این ساختار ممکن است پیش از برخی جنبه‌های دیگر شکل بگیرند. بنابراین، توصیف دقیق‌تر این پدیده نیازمند توجه به

مسیر رسیدن به ساختار نهایی است، نه فقط اندازه‌گیری وضعیت نهایی پس از پایان آموزش.

همچنین، تفاوت میان رفتار معیارهای پیوسته و معیارهای گسسته در تفسیر آموزش اهمیت دارد. دقت طبقه‌بندی یک کمیت گسسته است و ممکن است پس از رسیدن به مقدار حداکثری، اطلاعات کمی درباره‌ی تغییرات بعدی شبکه ارائه کند. در مقابل، تابع زیان و معیارهای مربوط به بازنمایی می‌توانند همچنان تغییرات تدریجی را ثبت کنند. بنابراین، ثابت‌ماندن یک معیار عملکردی لزوماً به معنای ثابت‌ماندن وضعیت داخلی شبکه نیست. این تفاوت توضیح می‌دهد که چرا بررسی همزمان چند نوع کمیت می‌تواند تصویر دقیق‌تری از مراحل پایانی آموزش فراهم کند.

از این نتیجه می‌توان برداشت عملی دیگری نیز داشت. اگر هدف از آموزش صرفاً دستیابی به یک سطح مشخص از عملکرد باشد، رسیدن به آن عملکرد می‌تواند معیار مناسبی برای تصمیم‌گیری عملی درباره‌ی توقف آموزش باشد. اما اگر هدف مطالعه‌ی ساختار بازنمایی، هندسه‌ی ویژگی یا ویژگی‌های مرتبط با فروپاشی عصبی باشد، چنین معیاری به تنهایی کافی نیست. در این حالت، نقطه‌ی توقف باید با توجه به کمیتی تعریف شود که مستقیماً با سؤال پژوهش مرتبط است. به عبارت دیگر، «پایان آموزش» یک مفهوم مطلق نیست و می‌تواند با توجه به هدف تحلیل، تعریف متفاوتی داشته باشد.

در مجموع، تصویر حاصل از این پژوهش بیشتر از آنکه آموزش را به عنوان یک فرایند با یک نقطه‌ی پایان مشخص نشان دهد، آن را به صورت مجموعه‌ای از تغییرات به‌هم‌پیوسته اما غیرهمزمان توصیف می‌کند. عملکرد شبکه، بازنمایی‌های داخلی و هندسه‌ی فضای ویژگی همگی در نتیجه‌ی بهینه‌سازی تغییر می‌کنند، اما الزاماً در یک لحظه به وضعیت پایدار نمی‌رسند. اهمیت اصلی این مشاهده در آن است که تحلیل دینامیک آموزش را از یک بررسی صرفاً مبتنی بر عملکرد، به مطالعه‌ای درباره‌ی تحول ساختار درونی شبکه گسترش می‌دهد.

بر این اساس، چارچوب به‌کاررفته در این پژوهش را می‌توان گامی در جهت توصیف چندبعدی فرایند آموزش دانست. استفاده‌ی همزمان از معیارهای عملکردی، شباهت بازنمایی و ویژگی‌های هندسی اجازه می‌دهد مراحل مختلف تحول شبکه از یکدیگر تفکیک شوند. این دیدگاه نه‌تنها تفسیر دقیق‌تری از نتایج آزمایش حاضر فراهم می‌کند، بلکه زمینه‌ای برای بررسی دقیق‌تر این پرسش ایجاد می‌کند که آیا الگوهای زمانی مشاهده‌شده ویژگی عمومی یادگیری شبکه‌های عمیق هستند یا

به معماری، داده و شیوه‌ی آموزش وابسته‌اند.

۲.۵ کارهای آینده

اگرچه نتایج این پژوهش شواهدی درباره‌ی ارتباط میان تکامل بازنمایی‌ها، تثبیت ساختارهای داخلی و ظهور ویژگی‌های مرتبط با فروپاشی عصبی ارائه می‌کنند، بررسی حاضر به یک معماری، یک مجموعه‌داده و یک تنظیم آموزشی محدود است. بنابراین، یکی از مهم‌ترین مسیرهای پژوهش آینده، بررسی میزان تعمیم‌پذیری این یافته‌ها در شرایط متفاوت خواهد بود.

در گام نخست، می‌توان آزمایش حاضر را بر روی مجموعه‌داده‌ی CIFAR-100 تکرار کرد. در مقایسه با CIFAR-10، این مجموعه‌داده دارای تعداد کلاس‌های بیشتری است و ساختار مسئله‌ی طبقه‌بندی پیچیده‌تر می‌شود. تکرار تحلیل‌های CKA و فروپاشی عصبی در این شرایط می‌تواند مشخص کند که آیا الگوی مشاهده‌شده برای زمان‌بندی تثبیت بازنمایی‌ها و شکل‌گیری ساختار هندسی، با افزایش تعداد کلاس‌ها نیز حفظ می‌شود یا خیر.

مسیر مهم دیگر، بررسی وابستگی نتایج به معماری شبکه است. در این پژوهش از ResNet-18 استفاده شد، در حالی که معماری‌های متفاوت ممکن است دینامیک بازنمایی و فروپاشی عصبی متفاوتی داشته باشند. به عنوان نمونه، اجرای همین آزمایش بر روی VGG-16 امکان مقایسه‌ی شبکه‌ای با ساختار متفاوت و فاقد اتصالات باقی‌مانده‌ی ResNet را فراهم می‌کند. همچنین، استفاده از Wide ResNet می‌تواند اثر افزایش پهنای شبکه بر زمان‌بندی تثبیت بازنمایی‌ها، هندسه‌ی فضای ویژگی و ظهور فروپاشی عصبی را بررسی کند.

ترکیب این آزمایش‌ها می‌تواند یک ماتریس مقایسه‌ای از معماری‌ها و مجموعه‌داده‌ها ایجاد کند و مشخص سازد که کدام یافته‌ها مستقل از معماری و داده هستند و کدام ویژگی‌ها به یک تنظیم خاص وابسته‌اند. به طور مشخص، می‌توان زمان تثبیت CKA و NC را در معماری‌ها و مجموعه‌داده‌های مختلف با یک چارچوب یکسان محاسبه و مقایسه کرد.

مسیر مهم دیگر، بررسی ساختار زیرفضاهای ویژگی[1] است. معیارهای CKA و NC اطلاعاتی

[1] Eigenspace

درباره‌ی شباهت بازنمایی و ویژگی‌های هندسی آن ارائه می‌کنند، اما بررسی مستقیم مقادیر ویژه و بردارهای ویژه‌ی ماتریس‌های مرتبط با بازنمایی می‌تواند اطلاعات دقیق‌تری درباره‌ی نحوه‌ی سازمان‌دهی اطلاعات در فضای ویژگی فراهم کند. برای مثال، می‌توان طیف مقادیر ویژه‌ی ماتریس کوواریانس ویژگی را در طول آموزش دنبال کرد و بررسی کرد که آیا بخش عمده‌ای از انرژی بازنمایی به تدریج در زیرفضاهای کم‌بعدتر متمرکز می‌شود یا خیر.

همچنین می‌توان پایداری خود زیرفضاهای ویژه را در طول آموزش بررسی کرد. به جای مقایسه‌ی صرف مقادیر CKA می‌توان زاویه‌ها یا میزان هم‌پوشانی میان زیرفضاهای اصلی در دوره‌های مختلف را اندازه‌گیری کرد. این تحلیل می‌تواند مشخص کند که آیا تثبیت مشاهده‌شده توسط CKA ناشی از تثبیت واقعی زیرفضاهای اصلی بازنمایی است یا تغییرات در جهات کم‌اهمیت‌تر نیز در مقدار CKA نقش دارند.

در ادامه، بررسی رابطه‌ی میان زیرفضاهای ویژگی و فروپاشی عصبی نیز می‌تواند دیدگاه دقیق‌تری درباره‌ی شکل‌گیری هندسه‌ی فضای ویژگی ارائه کند. به طور خاص، می‌توان بررسی کرد که آیا نزدیک‌شدن کلاس‌میانگین‌ها به ساختار سادک چارچوب تنگ هم‌زاویه با تغییرات مشخصی در طیف یا زیرفضاهای غالب بازنمایی همراه است یا خیر. چنین تحلیلی می‌تواند ارتباط میان ساختار آماری بازنمایی و هندسه‌ی کلاس‌میانگین‌ها را به صورت مستقیم‌تری بررسی کند.

از سوی دیگر، در پژوهش حاضر CKA با استفاده از بازنمایی نهایی در دوره‌ی ۳۵۰ به عنوان مرجع محاسبه شد. در مطالعات آینده می‌توان این انتخاب را با روش‌های دیگری مقایسه کرد. برای مثال، می‌توان بازنمایی‌های چندین نقطه‌ی بازرسی را به صورت جفتی با یکدیگر مقایسه کرد یا از یک مرجع متحرک برای بررسی تغییرات محلی بازنمایی استفاده کرد. این کار می‌تواند مشخص کند که نتایج تثبیت تا چه اندازه به انتخاب بازنمایی نهایی به عنوان مرجع وابسته هستند.

همچنین می‌توان تعریف‌های متفاوتی از تثبیت را بررسی کرد. در پژوهش حاضر، تثبیت با استفاده از یک آستانه و شرط سخت‌گیرانه‌ی باقی‌ماندن معیار در بالای آن آستانه تعریف شد. در آینده می‌توان این روش را با معیارهای مبتنی بر شیب تغییرات، تغییرات نسبی، پنجره‌های زمانی مختلف و روش‌های آماری مقایسه کرد. این موضوع به ویژه برای مقایسه‌ی مستقیم زمان‌بندی CKA و NC اهمیت دارد، زیرا این معیارها مقیاس‌ها و ویژگی‌های متفاوتی دارند و استفاده از معیارهای

تثبیت یکسان می‌تواند به تفسیرهای گمراه‌کننده منجر شود.

در نهایت، تحلیل حاضر با توسعه‌ی آزمایش به CIFAR-100، VGG-16 و Wide ResNet، در کنار تحلیل زیرفضاهای ویژگی، طیف مقادیر ویژه و هندسه‌ی سادک می‌تواند تصویری جامع‌تر از رابطه‌ی میان تثبیت بازنمایی، تکامل هندسی و فروپاشی عصبی ارائه دهد. این مطالعات همچنین می‌توانند مشخص کنند که آیا الگوی چندمرحله‌ای مشاهده‌شده در این پژوهش یک ویژگی عمومی از یادگیری شبکه‌های عمیق است یا نتیجه‌ای وابسته به معماری و مجموعه‌داده‌ی مورد استفاده.

واژه‌نامه انگلیسی به فارسی

تابع فعال‌سازی ..... Activation
افاین ..... Affine
افاین مستقل ..... Affinely Independent
هم‌تراز ..... Align
تجمع میانگین ..... Average Pooling
پس‌انتشار خطا ..... Backpropagation
دسته ..... Batch
بایاس ..... Bias
تحلیل همبستگی کانونی ..... Canonical Correlation Analysis (CCA)
هم‌ترازی کرنل مرکزی ..... Centered Kernel Alignment (CKA)
ماتریس مرکزساز ..... Centering Matrix
نقطه بازرسی ..... Checkpoint
پوش محدب ..... Convex Hull
شبکه‌های کانولوشنی عمیق ..... Convolutional Deep Networks
همبستگی ..... Correlation
زمان‌بند کاهش کسینوسی ..... Cosine Annealing
تابع زیان آنتروپی متقاطع ..... Cross-Entropy Loss
افزایش داده ..... Data Augmentation
شبکه‌های عصبی عمیق ..... Deep Neural Network
وابستگی ..... Dependency
زیرفضای ویژگی ..... Eigenspace
عنصری ..... Element-wise
دوره ..... Epoch
چارچوب تنگ هم‌زاویه ..... Equiangular Tight Frame (ETF)

لایهٔ کاملاً متصل ..... Fully Connected

کرنل تابع پایه شعاعی گاوسی ..... Gaussian Radial Basis (RBF)

ماتریس گِرَم ..... Gram Matrix

معیار استقلال هیلبرت‌ـاشمیت ..... Hilbert Schmidt Independence Criterion

ناوردایی ..... Invariance

مقیاس‌گذاری همسانگرد ..... Isotropic Scaling

کرنل ..... Kernel

تراز کرنل ..... Kernel Alignment

برچسب ..... Label

فضای نهان ..... Latent Space

خمینه ..... Manifold

تجمع بیشینه ..... Max Pooling

مومنتوم ..... Momentum

شبکه‌های عصبی چندلایه ..... Multilayer Perceptron (MLP)

فروپاشی عصبی ..... Neural Collapse

اندازه ..... Norm

حاشیه‌گذاری ..... Padding

پرسپترون ..... Perceptron

نیمه‌معین مثبت ..... Positive Semi-definite

تحلیل مؤلفه‌های اصلی ..... Principal Component Analysis(PCA)

همبستگی وزنی جزئی با تصویر ..... PWCCA

برش تصادفی ..... Random Crop

قرینه افقی ..... Random Horizontal Flip

بازنمایی ..... Representation

یادگیری بازنمایی ..... Representation Learning

شباهت نمایش‌ها ..... Representation Similarity

شبکه‌های باقیمانده ..... Residual Networks (ResNet)

فضای هیلبرت با کرنل بازتولیدکننده ..... RKHS

خود دوگانگی ..... Self Duality

معنایی ..... Semantic

سادک ..... Simplex

مسیر میان‌بُر ..... Skip Connection

گرادیان کاهشی تصادفی ..... Stochastic Gradient Descent (SGD)

پایداری سخت ..... Strict Stabilization

تحلیل همبستگی کانونی بردارهای تکین ..... SVCCA

تجزیه مقادیر تکین ..... SVD

تانسور ..... Tensor

فاز پایانی آموزش ..... Terminal Phase of Training (TPT)

افول وزن ..... Weight Decay

کتاب‌نامه

[1] G. Naitzat, A. Zhitnikov, and C.-N. Chen, "Topology of deep neural networks," *Machine Learning: Science and Technology*, vol. 1, no. 3, p. 035004, 2020.

[2] B. Ghojogh, A. Ghodsi, F. Karray, and M. Crowley, *Dimensionality Reduction: A Comparative Review*, Cham, Switzerland: Springer, 2023.

[3] S. Kornblith, M. Norouzi, H. Lee, and G. Hinton, "Similarity of neural network representations revisited," in *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 3519–3529, 2019.

[4] F. Anselmi, L. Rosasco, C. Tan, and T. Poggio, "Hierarchical invariance and stability in deep architectures," *arXiv preprint arXiv:1511.05930*, 2015.

[5] M. Raghu, J. Gilmer, J. Yosinski, and S. Sohl-Dickstein, "SVCCA: Singular vector canonical correlation analysis for deep learning dynamics and interpretability," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[6] A. Morcos, M. Raghu, and S. Bengio, "Insights on representational similarity in neural networks with canonical correlation," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 31, 2018.

[7] V. Papyan, X. Y. Han, and D. L. Donoho, "Prevalence of neural collapse during the terminal phase of deep learning training," *Proceedings of the National Academy of Sciences*, vol. 117, no. 40, pp. 24652–24663, 2020.

[8] A. Gretton, O. Bousquet, A. Smola, and B. Schölkopf, "Measuring statistical dependence with Hilbert-Schmidt norms," in *Proceedings of the International Conference on Algorithmic Learning Theory*, pp. 63–77, Springer, 2005.

[9] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. Cambridge, MA, MIT Press, 2016.

[10] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[11] Y. Bengio, A. Courville, and P. Vincent, "Representation learning: A review and new perspectives," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.

[12] A. Torralba, P. Isola, and W. T. Freeman, "Representation Learning," in *Foundations of Computer Vision*, Chapter 30, Cambridge, MA, USA: MIT Press, 2024.

[13] R. Pramoditha, "The Concept of Artificial Neurons (Perceptrons) in Neural Networks," *Towards Data Science*, December 2021.

[14] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.

Abstract

Deep neural networks can achieve high classification accuracy, but reaching high accuracy does not necessarily mean that the network's internal representations have become stable. Examining changes in these representations can provide a better understanding of the learning and convergence processes of deep neural networks.

In this study, the evolution of internal representations and the geometric structure of learned features during the training of a ResNet-18 network on the CIFAR-10 dataset is investigated. The network was trained for 350 epochs. To examine changes in representations, Centered Kernel Alignment was used to compare the representations of different layers at different training epochs with their final representations. In addition, the geometric structure of the features was evaluated using measures related to within-class variability, inter-class separation, the relationship between features and the classifier, and the agreement between network predictions and predictions based on class feature means. Training accuracy and the loss function were also used to evaluate model performance throughout training.

The first convolutional layer reaches high similarity to its final representation much earlier than the other layers, whereas the remaining layers, and the deeper ones in particular, keep changing until late in training. Furthermore, the geometric structure of the features can continue to change even after training accuracy reaches values close to 100%.

Overall, the findings indicate that the network's learning process continues to evolve in terms of its representational structure during the later stages of training. Differences in the stabilization times of the layers and the continued formation of the geometric structure of the features show

that functional convergence of the network does not necessarily coincide with convergence of its internal representations. Therefore, studying the evolution of representations can provide a more precise understanding of the learning process of deep neural networks.

Keywords: Internal Representation Changes, Centered Kernel Alignment, Geometric Structure of Features, Representation Learning, CIFAR-10, ResNet-18



College of Science

School of Mathematics, Statistics, and Computer Science

Geometrical Analysis of Deep Neural Networks

Parinaz Ghasemi

Supervisor: **Dr. Arta Jamshidi**

A project submitted in partial fulfillment of the requirements for the degree of B.Sc. in Computer Science

September 2026